المدرسة الوطنية للعلوم التطبيقية – أكادير
ⵜⴰⵙⴷⴰⵡⵜ ⵜⴰⵏⴰⵎⵓⵔⵜ ⵏ ⵜⵣⵔⴼⵜ ⵜⵉⵜⵜⴰⵏⵉⵜ - ⴰⴳⴰⴷⵉⵔ
ÉCOLE NATIONALE DES SCIENCES APPLIQUÉES - AGADIR

École Nationale des Sciences Appliquées d'Agadir

Rapport du Projet

Réalisé par :

Reda Erraoui

Spécialité : *Finance et Ingénierie Décisionnelle*

Étude économétrique et prévision du cours boursier de Managem

---

Encadrée par : Mme. Soukaina HADIRI

ENSA4/FID/2025-2026

Résumé

Ce travail porte sur l'analyse économétrique et la prévision d'une série temporelle financière, à travers l'étude du cours boursier du titre Managem. L'objectif principal est d'analyser la dynamique temporelle de la série, d'identifier ses propriétés statistiques et de proposer un modèle économétrique pertinent permettant d'effectuer des prévisions hors échantillon.

Dans un premier temps, une analyse exploratoire de la série est réalisée à l'aide de représentations graphiques, de statistiques descriptives et de corrélogrammes. La question de la stationnarité est ensuite étudiée à l'aide de tests de racine unitaire, notamment les tests de Dickey-Fuller, Dickey-Fuller augmenté et Phillips-Perron. Afin de rendre la série stationnaire, une transformation appropriée est appliquée, conduisant à la modélisation de la série stationnarisée.

La dynamique de la série est alors modélisée à l'aide de modèles ARMA, sélectionnés sur la base des fonctions d'autocorrélation, des critères d'information et des tests de validation des résidus. Une comparaison avec d'autres familles de modèles de séries temporelles est également menée afin de retenir la spécification la plus pertinente. Le modèle final est ensuite utilisé pour réaliser des prévisions hors échantillon, dont la qualité est évaluée à l'aide d'indicateurs d'erreur.

Par ailleurs, l'impact d'un événement économique ou financier significatif sur la série étudiée est analysé afin de mettre en évidence la sensibilité du titre aux chocs externes. Enfin, une méthode simple d'intelligence artificielle est mise en œuvre pour la prévision de la série, et ses performances sont comparées à celles du modèle économétrique retenu. Les résultats obtenus permettent de souligner les apports et les limites des approches économétriques et des méthodes d'intelligence artificielle dans l'analyse et la prévision des séries financières.

Mots clés : séries temporelles financières, économétrie, stationnarité, tests de racine unitaire, Dickey–Fuller, Phillips–Perron, rendements logarithmiques, modèles ARMA, diagnostics des résidus, volatilité, modèles GARCH, prévision hors échantillon, événement économique, corrélation, intelligence artificielle.

Liste des abréviations

ACF	Autocorrelation Function (Fonction d'Autocorrélation)
ADF	Augmented Dickey-Fuller (Test de Dickey-Fuller Augmenté)
ARCH	AutoRegressive Conditional Heteroskedasticity (Hétéroscédasticité Conditionnelle Autorégressive)
ARFIMA	AutoRegressive Fractionally Integrated Moving Average (Modèle Autorégressif à Intégration Fractionnaire)
ARIMA	AutoRegressive Integrated Moving Average (Modèle Autorégressif Intégré à Moyenne Mobile)
ARMA	AutoRegressive Moving Average (Modèle Autorégressif à Moyenne Mobile)
AIC	Akaike Information Criterion (Critère d'Information d'Akaike)
BIC	Bayesian Information Criterion (Critère d'Information Bayésien)
EGARCH	Exponential Generalized AutoRegressive Conditional Heteroskedasticity (Modèle GARCH Exponentiel)
GARCH	Generalized AutoRegressive Conditional Heteroskedasticity (Hétéroscédasticité Conditionnelle Autorégressive Généralisée)
IA	Intelligence Artificielle
LSTM	Long Short-Term Memory (Réseau Neuronal Récurrent à Mémoire Longue Courte)
MAE	Mean Absolute Error (Erreur Absolue Moyenne)
MLP	Multi-Layer Perceptron (Perceptron Multicouche)
MSE	Mean Squared Error (Erreur Quadratique Moyenne)
PACF	Partial Autocorrelation Function (Fonction d'Autocorrélation Partielle)
RMSE	Root Mean Squared Error (Racine de l'Erreur Quadratique Moyenne)
SARIMA	Seasonal AutoRegressive Integrated Moving Average (Modèle Autorégressif Intégré à Composante Saisonnière)
TARCH	Threshold AutoRegressive Conditional Heteroskedasticity (Modèle ARCH à Seuil)
VAR	Value at Risk (Valeur en Risque)
WLS	Weighted Least Squares (Moindres Carrés Pondérés)

Liste des figures

1.1 Évolution du cours boursier du titre Managem (juillet 2000 – janvier 2026) . . . 3
1.2 Statistiques descriptives du cours de clôture du titre Managem 4
1.3 Correlogrammes ACF et PACF du cours de Managem en niveau 5

2.1 Test ADF appliqué au cours de Managem en niveau 9
2.2 Test ADF appliqué au logarithme du cours de Managem 10
2.3 Test ADF appliqué aux rendements du titre Managem 11
2.4 Test Phillips–Perron appliqué au cours de Managem en niveau 12
2.5 Test Phillips–Perron appliqué aux rendements du titre Managem 13

3.1 Fonctions ACF et PACF des rendements 16
3.2 Estimation du modèle ARMA(1,1) 20
3.3 Corrélogramme des résidus du modèle ARMA(1,1) 21
3.4 Histogramme des résidus et test de Jarque–Bera 22
3.5 Test ARCH–LM appliqué aux résidus du modèle ARMA 23
3.6 Estimation du modèle GARCH(1,1) 24
3.7 Estimation du modèle TARCH 25
3.8 Estimation du modèle EGARCH(1,1) 26
3.9 Test ARCH–LM appliqué aux résidus standardisés 27

4.1 Prévision hors échantillon des rendements du titre Managem (moyenne conditionnelle) avec bandes de confiance à ±2 écarts-types. 29
4.2 Prévision hors échantillon de la variance conditionnelle (volatilité) issue du modèle GARCH. 30

5.1 Évolution conjointe du cours de Managem et du prix de l'or (en MAD). 37
5.2 Comparaison des variations relatives (base 100) entre le cours de Managem (courbe bleue) et le prix de l'or en MAD (courbe orange). 38

6.1 Comparaison des prévisions hors échantillon : Réel (bleu), ARMA(1,1) (orange) et MLP (vert) 43

Liste des tableaux

5.1 Résultats OLS – Modèle complet (Or, Argent, Cuivre) 35
5.2 Résultats OLS – Modèle réduit (Or, Argent) 35
5.3 Comparaison synthétique – Modèle complet vs modèle réduit 36
5.4 Modèle final retenu – Régression du cours de Managem sur le prix de l'or (MAD) 36

Table des matières

Résumé **2**

Introduction générale **1**

1 Présentation et analyse exploratoire de la série **2**

1.1 Présentation économique de la série 3

1.2 Analyse graphique et statistique de la série 3

1.2.1 Analyse graphique 3

1.2.2 Analyse statistique descriptive 4

1.3 Analyse des autocorrélations 5

1.3.1 Fonction d'autocorrélation et fonction d'autocorrélation partielle 5

2 Étude de la stationnarité de la série **7**

2.1 Rappel théorique sur la stationnarité 8

2.2 Méthodologie des tests de racine unitaire 8

2.2.1 Principe des tests de racine unitaire 8

2.3 Résultats empiriques des tests de stationnarité 9

2.3.1 Test de stationnarité du cours en niveau 9

2.3.2 Test de stationnarité du logarithme du cours 10

2.3.3 Test de stationnarité des rendements 11

2.3.4 Test de Phillips–Perron 12

2.4 Synthèse des résultats et ordre d'intégration 14

3 Modélisation ARMA–GARCH de la dynamique et de la volatilité des rendements **15**

3.1 Introduction 15

3.2 Modélisation de la moyenne conditionnelle 15

3.2.1 Cadre théorique du modèle ARMA 15

3.2.2 Identification par les fonctions ACF et PACF 16

3.2.3 Justification du choix du modèle ARMA : exclusion des modèles ARFIMA et SARIMA 17

3.2.3.1 Exclusion du modèle ARFIMA 17
3.2.3.2 Exclusion du modèle SARIMA 18
3.2.3.3 Choix final du modèle ARMA 18
3.2.4 Synthèse du choix de la spécification retenue 19
3.2.5 Estimation du modèle ARMA(1,1) 19
3.3 Diagnostic des résidus du modèle ARMA 21
3.3.1 Autocorrélation des résidus 21
3.3.2 Normalité des résidus 22
3.3.3 Test d'hétéroscédasticité conditionnelle 22
3.4 Modélisation de la volatilité conditionnelle 23
3.4.1 Modèle GARCH(1,1) 23
3.4.2 Asymétrie de la volatilité : modèle TARCH 25
3.4.3 Modèle EGARCH 26
3.5 Validation finale 27
3.6 Conclusion 27

4 Prévision et analyse du risque à partir des modèles ARMA–GARCH 28
4.1 Introduction 28
4.2 Prévision de la moyenne conditionnelle 28
4.2.1 Principe de la prévision ARMA 28
4.2.2 Résultats de prévision 28
4.3 Prévision de la volatilité conditionnelle 29
4.3.1 Volatilité conditionnelle issue des modèles GARCH 29
4.3.2 Analyse économique de la volatilité prévue 29
4.4 Mesure du risque : Value-at-Risk 31
4.4.1 Définition de la Value-at-Risk 31
4.4.2 VaR conditionnelle basée sur les modèles GARCH 31
4.5 Discussion économique 31
4.6 Conclusion 31

5 Impact de la hausse récente des prix des matières premières sur le titre Managem 33
5.1 Introduction 33
5.2 Contexte macroéconomique récent 33

5.3 Analyse descriptive du titre Managem 34
5.4 Analyse économétrique de la sensibilité aux matières premières 34
5.4.1 Données et principe d'estimation 34
5.4.2 Modèle complet (Or, Argent, Cuivre) 34
5.4.3 Modèle réduit (Or, Argent) 35
5.4.4 Comparaison des modèles et sélection 36
5.4.5 Modèle final retenu (Or seul) 36
5.4.6 Interprétation statistique et économique 36
5.5 Illustration graphique de la relation (après sélection du modèle final) 37
5.5.1 Comparaison en niveaux : Managem vs Or (MAD) 37
5.5.2 Comparaison en base 100 : dynamique relative 37
5.6 Lien avec la dynamique du risque (ARMA–GARCH) 38
5.7 Discussion méthodologique 38
5.8 Conclusion 39

6 Prévision par méthode d'intelligence artificielle 40
6.1 Introduction 40
6.2 Justification du choix du modèle neuronal 40
6.3 Fondements théoriques du réseau neuronal 41
6.4 Spécification empirique 42
6.5 Résultats empiriques 42
6.5.1 Analyse détaillée de la figure 43
6.6 Interprétation économique approfondie 43
6.7 Comparaison structurelle avec ARMA–GARCH 44
6.8 Conclusion 44

Conclusion Générale 45

Bibliographie 47

Introduction générale

Les séries temporelles occupent une place centrale en économétrie financière, dans la mesure où elles permettent d'analyser et de modéliser l'évolution des variables économiques et financières au cours du temps. Les marchés financiers se caractérisent par une forte dynamique, marquée par des phases de tendance, de volatilité et de ruptures liées à des événements économiques ou financiers. L'étude de ces séries constitue ainsi un outil fondamental pour la compréhension des mécanismes de marché et pour l'aide à la prise de décision.

Dans ce contexte, le présent travail s'intéresse à l'analyse du cours boursier du titre Managem, une entreprise opérant dans le secteur minier et dont l'activité est étroitement liée à l'évolution des marchés des matières premières. Le choix de cette série se justifie par son intérêt économique et financier, ainsi que par la sensibilité potentielle de son cours aux chocs externes, notamment ceux liés aux fluctuations des prix des métaux précieux et aux conditions générales des marchés financiers.

L'objectif principal de ce projet est d'étudier les propriétés statistiques de la série considérée, d'analyser sa dynamique temporelle et de proposer un modèle économétrique pertinent permettant d'effectuer des prévisions hors échantillon. Pour ce faire, une démarche rigoureuse en plusieurs étapes est adoptée. Dans un premier temps, une analyse exploratoire de la série est réalisée à travers des représentations graphiques, des statistiques descriptives et l'étude des autocorrélations. La question de la stationnarité est ensuite examinée à l'aide des principaux tests de racine unitaire présentés en cours.

Une fois la série rendue stationnaire, la modélisation économétrique est menée à l'aide de modèles de séries temporelles adaptés, en particulier les modèles ARMA. La validité du modèle retenu est évaluée à l'aide de tests de diagnostic appliqués aux résidus estimés, et une comparaison avec d'autres familles de modèles est effectuée afin de retenir la spécification la plus appropriée. Le modèle final est ensuite utilisé pour réaliser des prévisions hors échantillon, dont la qualité est analysée à l'aide d'indicateurs de performance.

Par ailleurs, l'impact d'un événement économique ou financier significatif sur la série étudiée est analysé afin de mettre en évidence la réaction du titre face aux chocs externes. Enfin, une méthode simple d'intelligence artificielle est mise en œuvre pour la prévision de la série, et ses résultats sont comparés à ceux du modèle économétrique retenu.

1 Présentation et analyse exploratoire de la série

Objectifs du chapitre

Ce chapitre a pour objectif de poser les bases empiriques de l'analyse économétrique de la série temporelle étudiée. Il vise à examiner le comportement du cours boursier de Managem à travers une analyse exploratoire approfondie, préalable indispensable à toute modélisation des séries temporelles.

Plus précisément, ce chapitre cherche à identifier les principales caractéristiques statistiques de la série en niveau, en mettant en évidence sa tendance, son degré de volatilité et la nature de sa distribution. L'analyse graphique permet d'observer l'évolution globale du cours dans le temps et de détecter d'éventuelles irrégularités, tandis que les statistiques descriptives fournissent une première évaluation de la dispersion, de l'asymétrie et de l'aplatissement de la distribution.

L'étude des fonctions d'autocorrélation et d'autocorrélation partielle constitue également un élément central de cette analyse exploratoire. Elle permet d'évaluer la dépendance temporelle de la série et de formuler des hypothèses sur sa structure dynamique, notamment en ce qui concerne son éventuelle non-stationnarité.

Ainsi, ce chapitre a pour finalité de fournir un diagnostic préliminaire rigoureux du comportement temporel du cours boursier étudié, afin de justifier et d'orienter les choix méthodologiques qui seront adoptés dans les chapitres suivants, en particulier pour l'étude formelle de la stationnarité et la modélisation économétrique.

1.1 Présentation économique de la série

La série étudiée dans ce travail correspond au cours boursier du titre **Managem**, entreprise marocaine opérant principalement dans le secteur minier et cotée à la Bourse de Casablanca depuis le 11 juillet 2000. Le groupe Managem est spécialisé dans l'exploration, l'extraction et la commercialisation de plusieurs métaux, notamment les métaux précieux, ce qui rend son activité fortement dépendante de l'évolution des marchés internationaux des matières premières.

Le cours boursier de Managem reflète ainsi non seulement la performance financière propre de l'entreprise, mais également l'influence de facteurs macroéconomiques et financiers externes, tels que les fluctuations des prix des métaux, les conditions générales des marchés financiers et les anticipations des investisseurs. En particulier, le prix de l'or joue un rôle central en tant que valeur refuge, ce qui peut accentuer la sensibilité du titre lors des périodes d'incertitude économique ou financière.

La série est de fréquence mensuelle et couvre la période allant de juillet 2000 à janvier 2026, soit un total de 306 observations, permettant d'analyser plusieurs cycles économiques et financiers.

1.2 Analyse graphique et statistique de la série

1.2.1 Analyse graphique

La Figure 1.1 présente l'évolution du cours de clôture du titre Managem sur la période étudiée.

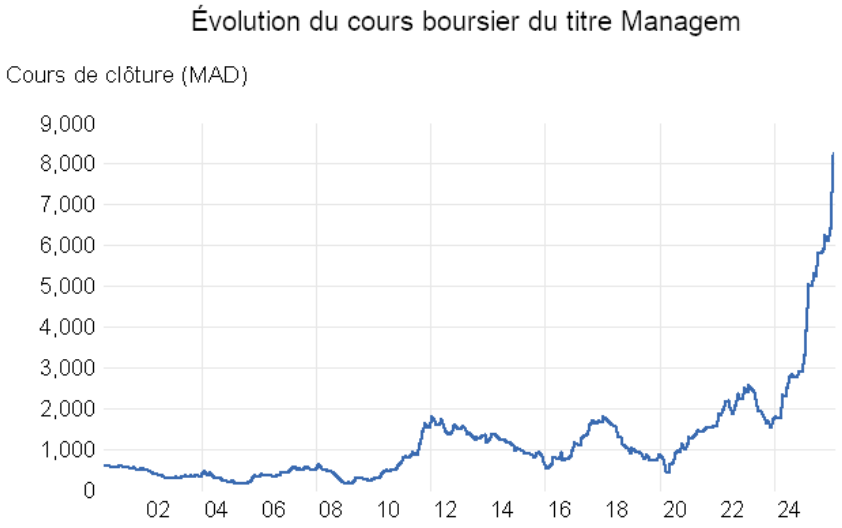


Figure 1.1 – Évolution du cours boursier du titre Managem (juillet 2000 – janvier 2026)

L'observation du graphique met en évidence une évolution non stationnaire du niveau de la série. On observe une tendance de long terme, ponctuée de phases de hausse et de baisse marquées, ainsi que des épisodes de forte volatilité. Ces fluctuations traduisent une sensibilité importante du titre aux conditions économiques et financières, ainsi qu'aux chocs externes affectant les marchés des matières premières.

Par ailleurs, l'amplitude des variations du cours augmente au fil du temps, suggérant une variance non constante, phénomène typique des séries financières.

1.2.2 Analyse statistique descriptive

Afin de compléter l'analyse graphique, une analyse statistique descriptive de la série en niveau a été réalisée à l'aide du logiciel EViews. Les principaux indicateurs sont présentés dans la Figure 1.2.

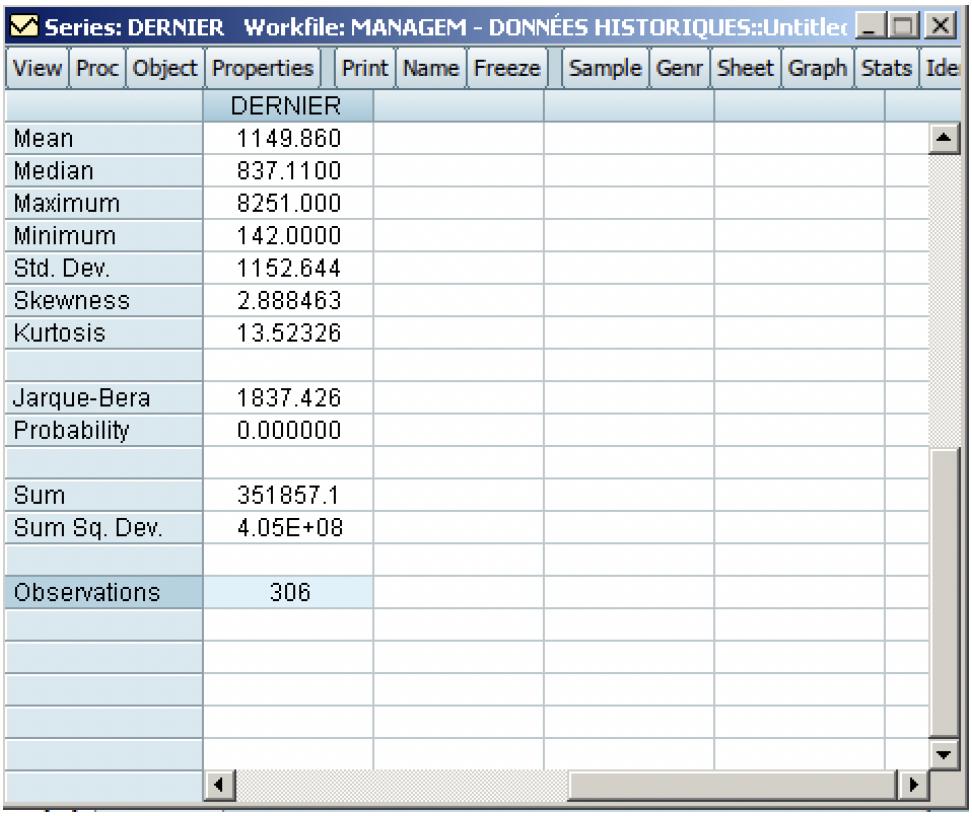


Figure 1.2 – Statistiques descriptives du cours de clôture du titre Managem

La moyenne du cours boursier s'élève à 1149.86 MAD, tandis que l'écart-type atteint 1152.64 MAD, indiquant une dispersion très élevée des observations. L'écart important entre la valeur minimale (142 MAD) et la valeur maximale (8251 MAD) reflète l'ampleur des variations du titre sur la période étudiée.

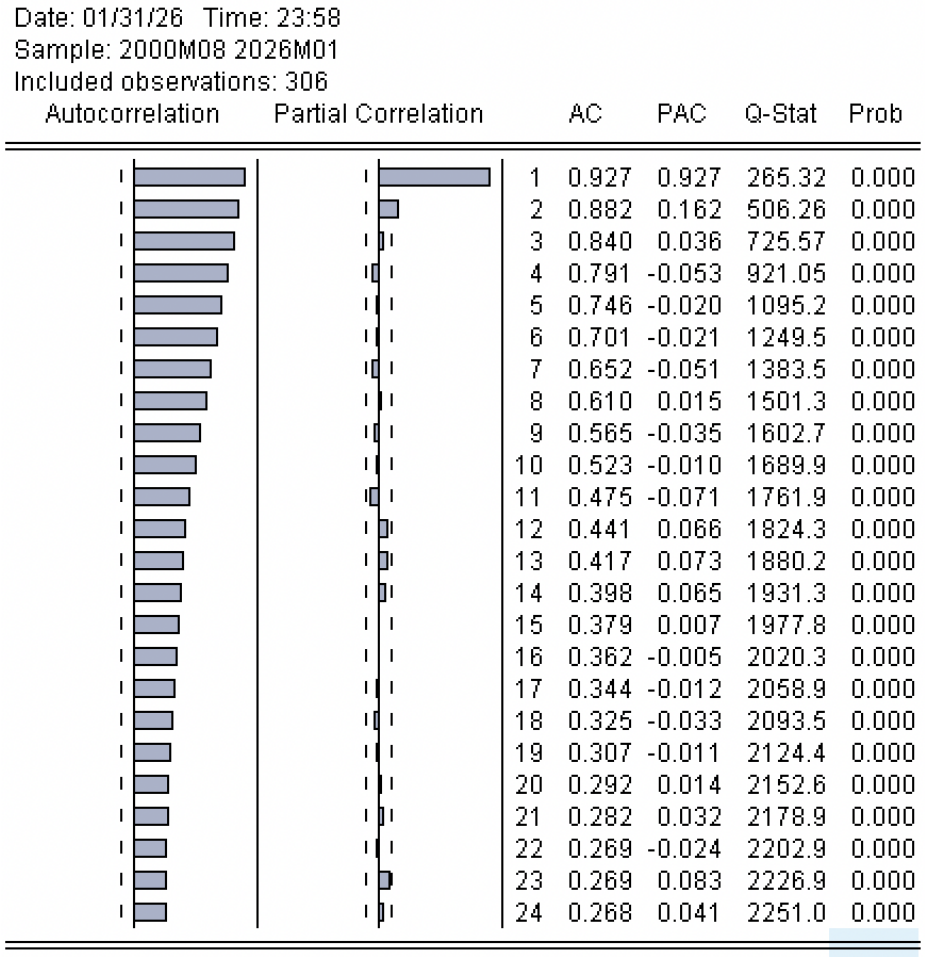
Le coefficient d'asymétrie est fortement positif, traduisant une distribution asymétrique à droite caractérisée par la présence de valeurs extrêmes élevées. Le coefficient d'aplatissement est largement supérieur à celui d'une loi normale, indiquant une distribution leptokurtique. Le test de Jarque–Bera conduit au rejet de l'hypothèse de normalité, résultat classique pour les séries financières.

1.3 Analyse des autocorrélations

L'analyse des fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) permet d'étudier la dépendance temporelle de la série et de fournir des indications essentielles sur sa structure dynamique.

1.3.1 Fonction d'autocorrélation et fonction d'autocorrélation partielle

Les corrélogrammes de la série du cours boursier de Managem en niveau sont présentés dans la Figure 1.3.



	AC	PAC	Q-Stat	Prob
1	0.927	0.927	265.32	0.000
2	0.882	0.162	506.26	0.000
3	0.840	0.036	725.57	0.000
4	0.791	-0.053	921.05	0.000
5	0.746	-0.020	1095.2	0.000
6	0.701	-0.021	1249.5	0.000
7	0.652	-0.051	1383.5	0.000
8	0.610	0.015	1501.3	0.000
9	0.565	-0.035	1602.7	0.000
10	0.523	-0.010	1689.9	0.000
11	0.475	-0.071	1761.9	0.000
12	0.441	0.066	1824.3	0.000
13	0.417	0.073	1880.2	0.000
14	0.398	0.065	1931.3	0.000
15	0.379	0.007	1977.8	0.000
16	0.362	-0.005	2020.3	0.000
17	0.344	-0.012	2058.9	0.000
18	0.325	-0.033	2093.5	0.000
19	0.307	-0.011	2124.4	0.000
20	0.292	0.014	2152.6	0.000
21	0.282	0.032	2178.9	0.000
22	0.269	-0.024	2202.9	0.000
23	0.269	0.083	2226.9	0.000
24	0.268	0.041	2251.0	0.000

Figure 1.3 – Correlogrammes ACF et PACF du cours de Managem en niveau

L'examen de la fonction d'autocorrélation met en évidence une persistance temporelle très marquée. La valeur de l'autocorrélation au premier retard est particulièrement élevée ($AC_1 \approx 0{,}927$), ce qui traduit une forte dépendance entre deux observations consécutives. De plus, l'ACF décroît lentement au fil des retards et reste positive et significative sur un grand nombre d'entre eux, avec notamment $AC_{12} \approx 0{,}441$ et $AC_{24} \approx 0{,}268$. Une telle décroissance progressive, sans annulation rapide, est caractéristique des séries non stationnaires en niveau et est généralement associée à la présence d'une racine unitaire.

La fonction d'autocorrélation partielle présente également un pic très marqué au premier retard ($PAC_1 \approx 0{,}927$), tandis que les retards suivants deviennent nettement plus faibles ($PAC_2 \approx 0{,}162$, puis des valeurs proches de zéro). L'absence de coupure nette de la PACF confirme que la dynamique de la série est dominée par une forte persistance plutôt que par un processus autorégressif de faible ordre.

Par ailleurs, les statistiques de Ljung–Box associées aux différents retards sont toutes hautement significatives (Prob = 0,000), ce qui conduit au rejet de l'hypothèse d'absence d'autocorrélation. La série ne peut donc pas être assimilée à un bruit blanc et présente une structure temporelle fortement dépendante.

Ces résultats confirment de manière robuste le caractère non stationnaire de la série du cours boursier de Managem en niveau et justifient la mise en œuvre de tests formels de stationnarité, tels que les tests de Dickey–Fuller augmenté et de Phillips–Perron, ainsi que l'application éventuelle de transformations comme la différenciation avant toute modélisation économétrique.

2 Étude de la stationnarité de la série

Objectifs du chapitre

L'objectif de ce chapitre est d'examiner de manière formelle la stationnarité de la série temporelle étudiée. La stationnarité constitue une hypothèse fondamentale en économétrie des séries temporelles, dans la mesure où la plupart des outils d'analyse et de modélisation reposent sur l'hypothèse d'invariance des propriétés statistiques du processus au cours du temps. En particulier, la validité des méthodes d'estimation, des tests statistiques et des prévisions dépend fortement du caractère stationnaire de la série analysée.

Dans le cas des séries financières, telles que les cours boursiers, la non-stationnarité est un phénomène fréquemment observé. Elle se manifeste généralement par la présence de tendances de long terme, de ruptures structurelles ou d'une variance non constante, traduisant le fait que les chocs affectant la série peuvent avoir des effets persistants dans le temps. Il est donc indispensable de vérifier formellement cette propriété avant toute tentative de modélisation économétrique.

Après un rappel théorique sur la notion de stationnarité et sur les tests de racine unitaire, nous appliquons les tests de Dickey–Fuller (DF), Dickey–Fuller augmenté (ADF) et Phillips–Perron (PP) à la série du cours boursier de Managem sous différentes transformations (niveau, logarithme et rendements), afin d'identifier une représentation stationnaire appropriée. Cette démarche permet de déterminer l'ordre d'intégration de la série et de sélectionner la forme la plus adaptée pour les analyses économétriques ultérieures.

2.1 Rappel théorique sur la stationnarité

Une série temporelle est dite *stationnaire* si ses principales caractéristiques statistiques, notamment l'espérance, la variance et la structure d'autocorrélation, sont invariantes dans le temps. En pratique, de nombreuses séries financières observées en niveau présentent une tendance ou une volatilité variable, ce qui les rend non stationnaires.

La présence d'une racine unitaire dans une série implique que les chocs affectant le processus ont un effet permanent, ce qui est typiquement le cas pour les cours boursiers. Afin de tester formellement cette propriété, on utilise des tests de racine unitaire, dont les plus couramment employés sont les tests de Dickey–Fuller, Dickey–Fuller augmenté et Phillips–Perron.

2.2 Méthodologie des tests de racine unitaire

2.2.1 Principe des tests de racine unitaire

Les tests de Dickey–Fuller reposent sur l'hypothèse nulle selon laquelle la série étudiée possède une racine unitaire, ce qui implique un comportement non stationnaire. Le test de Dickey–Fuller augmenté (ADF) étend cette approche en intégrant des retards supplémentaires afin de corriger l'autocorrélation des résidus. Le test de Phillips–Perron constitue une alternative non paramétrique, robuste à l'hétéroscédasticité et à l'autocorrélation des erreurs.

L'hypothèse nulle commune à ces tests est :

$$H_0 : \text{la série possède une racine unitaire}$$

contre l'hypothèse alternative :

$$H_1 : \text{la série est stationnaire}$$

Les longueurs de retard sont sélectionnées automatiquement à l'aide du critère d'information de Schwarz (SIC), avec un nombre maximal de retards égal à 15.

2.3 Résultats empiriques des tests de stationnarité

2.3.1 Test de stationnarité du cours en niveau

Nous appliquons dans un premier temps le test de Dickey–Fuller augmenté à la série du cours boursier de Managem en niveau (`DERNIER`), en incluant une constante et une tendance linéaire dans l'équation de test.

Null Hypothesis: DERNIER has a unit root
Exogenous: Constant, Linear Trend
Lag Length: 0 (Automatic - based on SIC, maxlag=15)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		5.876539	1.0000
Test critical values:	1% level	-3.988433	
	5% level	-3.424627	
	10% level	-3.135378	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(DERNIER)
Method: Least Squares
Date: 02/01/26 Time: 01:22
Sample (adjusted): 2000M09 2026M01
Included observations: 305 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DERNIER(-1)	0.068064	0.011582	5.876539	0.0000
C	-26.95036	17.97519	-1.499309	0.1348
@TREND("2000M08")	-0.161028	0.141849	-1.135209	0.2572

R-squared	0.147168	Mean dependent var	25.09180
Adjusted R-squared	0.141520	S.D. dependent var	167.7440
S.E. of regression	155.4218	Akaike info criterion	12.93995
Sum squared resid	7295094.	Schwarz criterion	12.97654
Log likelihood	-1970.342	Hannan-Quinn criter.	12.95459
F-statistic	26.05713	Durbin-Watson stat	1.546552
Prob(F-statistic)	0.000000		

Figure 2.1 – Test ADF appliqué au cours de Managem en niveau

Les résultats montrent que la statistique du test ADF est largement supérieure (en valeur absolue) aux valeurs critiques usuelles et que la p-valeur associée est élevée. Par conséquent, l'hypothèse nulle de présence d'une racine unitaire ne peut pas être rejetée.

On conclut donc que la série du cours de Managem en niveau est **non stationnaire**, ce qui confirme les observations issues de l'analyse graphique et des corrélogrammes du chapitre précédent.

2.3.2 Test de stationnarité du logarithme du cours

Afin de réduire l'amplitude des fluctuations et de stabiliser la variance, nous considérons ensuite le logarithme du cours boursier, noté `L_COURS`. Le test ADF est appliqué à cette série en incluant une constante dans l'équation de test.

Null Hypothesis: L_COURS has a unit root
Exogenous: Constant
Lag Length: 0 (Automatic - based on SIC, maxlag=15)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		0.439091	0.9843
Test critical values:	1% level	-3.451632	
	5% level	-2.870805	
	10% level	-2.571777	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(L_COURS)
Method: Least Squares
Date: 02/01/26 Time: 01:41
Sample (adjusted): 2000M09 2026M01
Included observations: 305 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
L_COURS(-1)	0.003478	0.007920	0.439091	0.6609
C	-0.014646	0.053350	-0.274531	0.7839

R-squared	0.000636	Mean dependent var	0.008605
Adjusted R-squared	-0.002662	S.D. dependent var	0.113308
S.E. of regression	0.113459	Akaike info criterion	-1.508222
Sum squared resid	3.900475	Schwarz criterion	-1.483826
Log likelihood	232.0038	Hannan-Quinn criter.	-1.498464
F-statistic	0.192801	Durbin-Watson stat	1.740212
Prob(F-statistic)	0.660908		

Figure 2.2 – Test ADF appliqué au logarithme du cours de Managem

Les résultats indiquent que la statistique ADF reste non significative et que la p-valeur est élevée. L'hypothèse nulle de racine unitaire ne peut donc pas être rejetée.

Ainsi, malgré la transformation logarithmique, la série demeure **non stationnaire**. Ce résultat suggère que la non-stationnarité est structurelle et liée à la nature même du processus de formation des prix.

2.3.3 Test de stationnarité des rendements

La transformation couramment utilisée en finance consiste à étudier les rendements, définis comme la différence première du logarithme du cours. On note cette série `RCOURS`.

Le test ADF est appliqué à la série des rendements, en incluant une constante dans l'équation de test.

Null Hypothesis: RCOURS has a unit root
Exogenous: Constant
Lag Length: 0 (Automatic - based on SIC, maxlag=15)

		t-Statistic	Prob.*
Augmented Dickey-Fuller test statistic		-15.16588	0.0000
Test critical values:	1% level	-3.451703	
	5% level	-2.870836	
	10% level	-2.571794	

*MacKinnon (1996) one-sided p-values.

Augmented Dickey-Fuller Test Equation
Dependent Variable: D(RCOURS)
Method: Least Squares
Date: 02/01/26 Time: 01:39
Sample (adjusted): 2000M10 2026M01
Included observations: 304 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
RCOURS(-1)	-0.872380	0.057523	-15.16588	0.0000
C	0.007694	0.006483	1.186796	0.2362

R-squared	0.432335	Mean dependent var	0.000891
Adjusted R-squared	0.430455	S.D. dependent var	0.149411
S.E. of regression	0.112758	Akaike info criterion	-1.520592
Sum squared resid	3.839724	Schwarz criterion	-1.496138
Log likelihood	233.1300	Hannan-Quinn criter.	-1.510810
F-statistic	230.0038	Durbin-Watson stat	1.991505
Prob(F-statistic)	0.000000		

Figure 2.3 – Test ADF appliqué aux rendements du titre Managem

Les résultats montrent que la statistique ADF est fortement négative et inférieure aux valeurs critiques aux seuils de 1%, 5% et 10%. La p-valeur associée est nulle, ce qui conduit à rejeter très fortement l'hypothèse nulle de racine unitaire.

On conclut ainsi que la série des rendements du titre Managem est **stationnaire**.

2.3.4 Test de Phillips–Perron

Afin de renforcer la robustesse des conclusions obtenues avec le test ADF, nous appliquons également le test de Phillips–Perron (PP), qui corrige l'hétéroscédasticité et l'autocorrélation des erreurs sans introduire explicitement de retards supplémentaires dans l'équation de test.

Null Hypothesis: DERNIER has a unit root
Exogenous: Constant
Bandwidth: 1 (Newey-West automatic) using Bartlett kernel

		Adj. t-Stat	Prob.*
Phillips-Perron test statistic		6.767542	1.0000
Test critical values:	1% level	-3.451632	
	5% level	-2.870805	
	10% level	-2.571777	

*MacKinnon (1996) one-sided p-values.

Residual variance (no correction)	24020.41
HAC corrected variance (Bartlett kernel)	25901.41

Phillips-Perron Test Equation
Dependent Variable: D(DERNIER)
Method: Least Squares
Date: 02/15/26 Time: 21:03
Sample (adjusted): 2000M09 2026M01
Included observations: 305 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
DERNIER(-1)	0.058839	0.008257	7.125811	0.0000
C	-41.19512	12.87670	-3.199199	0.0015

R-squared	0.143529	Mean dependent var	25.09180
Adjusted R-squared	0.140702	S.D. dependent var	167.7440
S.E. of regression	155.4958	Akaike info criterion	12.93765
Sum squared resid	7326224.	Schwarz criterion	12.96205
Log likelihood	-1970.992	Hannan-Quinn criter.	12.94741
F-statistic	50.77718	Durbin-Watson stat	1.529833
Prob(F-statistic)	0.000000		

Figure 2.4 – Test Phillips–Perron appliqué au cours de Managem en niveau

Les résultats du test PP appliqué à la série en niveau montrent que la statistique de test est positive et largement supérieure aux valeurs critiques aux seuils usuels. La p-valeur associée est élevée, ce qui conduit à ne pas rejeter l'hypothèse nulle de présence d'une racine unitaire.

La série du cours en niveau est donc confirmée comme **non stationnaire**.

Null Hypothesis: VARIATION__ has a unit root
Exogenous: Constant
Bandwidth: 4 (Newey-West automatic) using Bartlett kernel

		Adj. t-Stat	Prob.*
Phillips-Perron test statistic		-15.24724	0.0000
Test critical values:	1% level	-3.451632	
	5% level	-2.870805	
	10% level	-2.571777	

*MacKinnon (1996) one-sided p-values.

Residual variance (no correction)	131.2987
HAC corrected variance (Bartlett kernel)	142.5432

Phillips-Perron Test Equation
Dependent Variable: D(VARIATION__)
Method: Least Squares
Date: 02/15/26 Time: 21:05
Sample (adjusted): 2000M09 2026M01
Included observations: 305 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
VARIATION__(-1)	-0.870565	0.057508	-15.13812	0.0000
C	1.327995	0.663308	2.002080	0.0462

R-squared	0.430625	Mean dependent var	0.093705
Adjusted R-squared	0.428746	S.D. dependent var	15.21053
S.E. of regression	11.49632	Akaike info criterion	7.728467
Sum squared resid	40046.10	Schwarz criterion	7.752862
Log likelihood	-1176.591	Hannan-Quinn criter.	7.738224
F-statistic	229.1627	Durbin-Watson stat	1.990148
Prob(F-statistic)	0.000000		

Figure 2.5 – Test Phillips–Perron appliqué aux rendements du titre Managem

En revanche, pour la série des rendements, la statistique de Phillips–Perron est fortement négative et inférieure aux valeurs critiques aux seuils de 1%, 5% et 10%. La p-valeur est nulle, ce qui conduit à rejeter très fortement l'hypothèse nulle de racine unitaire.

La série des rendements est donc **stationnaire**.

Ces résultats confirment intégralement ceux obtenus avec le test ADF et permettent de conclure de manière robuste que le cours boursier de Managem est intégré d'ordre un, tandis que ses rendements sont stationnaires.

2.4 Synthèse des résultats et ordre d'intégration

Les tests de racine unitaire permettent de tirer les conclusions suivantes :

— le cours boursier de Managem en niveau est non stationnaire ;

— le logarithme du cours reste non stationnaire ;

— les rendements du titre sont stationnaires.

L'ensemble de ces résultats conduit à conclure que le cours boursier de Managem est intégré d'ordre un, noté $I(1)$. Autrement dit, la série est non stationnaire en niveau mais devient stationnaire après une différenciation, ce qui correspond à un comportement de type marche aléatoire avec dérive. Cette propriété est caractéristique des séries financières de prix.

Conclusion

Ce chapitre a permis d'identifier la représentation stationnaire appropriée de la série étudiée. La série des rendements sera utilisée dans la suite du travail pour la modélisation économétrique, notamment dans le cadre des modèles ARMA et GARCH, afin d'analyser la dynamique temporelle et la volatilité du titre Managem.

3 Modélisation ARMA–GARCH de la dynamique et de la volatilité des rendements

3.1 Introduction

Après l'étude des propriétés statistiques et de la stationnarité des rendements, ce chapitre est consacré à la modélisation dynamique de la série temporelle. L'objectif est double :

— modéliser la moyenne conditionnelle des rendements à l'aide d'un modèle ARMA ;

— modéliser la volatilité conditionnelle à l'aide des modèles ARCH, GARCH et de leurs extensions asymétriques.

Les rendements financiers présentent des propriétés stylisées bien connues, notamment une faible autocorrélation linéaire, une non-normalité marquée et une forte hétéroscédasticité conditionnelle. Ces caractéristiques justifient le recours à une modélisation conjointe de la moyenne et de la variance.

L'ensemble des estimations est réalisé à l'aide du logiciel **EViews**.

3.2 Modélisation de la moyenne conditionnelle

3.2.1 Cadre théorique du modèle ARMA

Un processus ARMA(p, q) s'écrit sous la forme :

$$R_t = \mu + \sum_{i=1}^{p} \phi_i R_{t-i} + \sum_{j=1}^{q} \theta_j \varepsilon_{t-j} + \varepsilon_t,$$

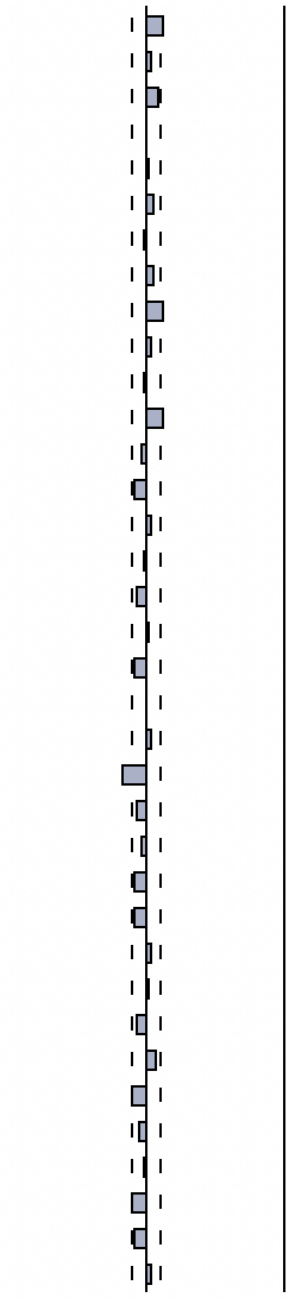
où ε_t est un bruit blanc de variance constante σ^2.

La stationnarité impose que les racines du polynôme autorégressif soient strictement supérieures à l'unité en valeur absolue, tandis que l'inversibilité impose une condition analogue sur la partie moyenne mobile.

3.2.2 Identification par les fonctions ACF et PACF

La Figure 3.1 présente les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) des rendements.

Date: 02/01/26 Time: 10:39
Sample (adjusted): 2000M09 2026M01
Included observations: 305 after adjustments



Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.126	0.126	4.8619	0.027
		2	0.040	0.025	5.3643	0.068
		3	0.096	0.089	8.2046	0.042
		4	0.000	-0.024	8.2046	0.084
		5	0.012	0.010	8.2475	0.143
		6	0.054	0.045	9.1659	0.164
		7	-0.012	-0.023	9.2116	0.238
		8	0.063	0.065	10.468	0.234
		9	0.122	0.102	15.176	0.086
		10	0.029	0.004	15.437	0.117
		11	-0.023	-0.045	15.601	0.157
		12	0.125	0.117	20.562	0.057
		13	-0.049	-0.078	21.325	0.067
		14	-0.096	-0.092	24.296	0.042
		15	0.037	0.039	24.750	0.053
		16	-0.022	-0.013	24.904	0.072
		17	-0.077	-0.080	26.846	0.060
		18	0.023	0.013	27.024	0.079
		19	-0.088	-0.075	29.562	0.058
		20	0.006	0.033	29.572	0.077
		21	0.038	0.010	30.040	0.091
		22	-0.182	-0.168	40.957	0.008
		23	-0.069	0.001	42.526	0.008
		24	-0.036	-0.047	42.948	0.010
		25	-0.096	-0.045	46.003	0.006
		26	-0.082	-0.034	48.286	0.005
		27	0.030	0.049	48.581	0.007
		28	0.016	0.039	48.665	0.009
		29	-0.068	-0.060	50.233	0.009
		30	0.078	0.091	52.314	0.007
		31	-0.108	-0.089	56.313	0.004
		32	-0.060	-0.016	57.556	0.004
		33	-0.014	-0.036	57.628	0.005
		34	-0.114	-0.031	62.100	0.002
		35	-0.090	-0.069	64.914	0.002
		36	0.025	-0.005	65.129	0.002

Figure 3.1 – Fonctions ACF et PACF des rendements

Interprétation : Plusieurs coefficients d'autocorrélation dépassent les bandes de confiance asymptotiques, et les statistiques de Ljung–Box associées présentent des p-values inférieures à 5% pour certains retards. L'hypothèse nulle de bruit blanc est donc rejetée.

D'un point de vue économétrique, ces résultats indiquent que la moyenne conditionnelle des rendements n'est pas constante et qu'une structure dépendante du passé doit être introduite. Sur le plan financier, cette dépendance de court terme peut être interprétée comme un effet d'ajustement progressif de l'information ou un effet de microstructure du marché.

Ces éléments justifient l'introduction d'un modèle ARMA pour la moyenne.

3.2.3 Justification du choix du modèle ARMA : exclusion des modèles ARFIMA et SARIMA

Avant de retenir définitivement la spécification ARMA pour la moyenne conditionnelle, d'autres classes de modèles ont été envisagées, notamment les modèles ARFIMA et SARIMA. Cette section justifie les raisons pour lesquelles ces modèles n'ont pas été retenus dans le cadre de cette étude.

3.2.3.1 Exclusion du modèle ARFIMA

Les modèles ARFIMA (AutoRegressive Fractionally Integrated Moving Average) permettent de modéliser des processus présentant une *mémoire longue*, caractérisée par une décroissance lente de la fonction d'autocorrélation, de type hyperbolique. Un modèle ARFIMA(p, d, q) s'écrit :

$$(1 - L)^d R_t = \phi(L) R_t + \theta(L)\varepsilon_t,$$

où $d \in (0, 1)$ représente un paramètre de différenciation fractionnaire.

Dans le cas présent, l'analyse empirique des rendements ne met pas en évidence de mémoire longue persistante :

- les fonctions ACF et PACF décroissent rapidement vers zéro ;
- aucune persistance de long terme n'est observée dans la moyenne ;
- les dépendances détectées sont essentiellement de court terme.

D'un point de vue économétrique, la série des rendements est stationnaire et ne nécessite pas de différenciation fractionnaire. Sur le plan financier, la mémoire longue est plus fréquemment observée dans les mesures de volatilité ou de volume, et non dans la moyenne des rendements.

Ainsi, l'utilisation d'un modèle ARFIMA conduirait à une sur-paramétrisation sans gain significatif en termes d'ajustement ou d'interprétation économique. Le modèle ARMA apparaît donc plus approprié et plus parcimonieux.

3.2.3.2 Exclusion du modèle SARIMA

Les modèles SARIMA (Seasonal ARIMA) sont destinés à modéliser des séries temporelles présentant une structure saisonnière déterministe ou stochastique. Un modèle SARIMA s'écrit généralement :

$$ARIMA(p, d, q) \times (P, D, Q)_s,$$

où s représente la périodicité saisonnière.

Dans le cas des rendements financiers étudiés, aucune saisonnalité claire n'est mise en évidence :

— les corrélogrammes ne présentent pas de pics significatifs à des retards liés à une périodicité fixe ;

— les statistiques de Ljung–Box ne révèlent pas de dépendance saisonnière ;

— la série des rendements est construite de manière à éliminer les effets de tendance et de cycle.

D'un point de vue économique, les rendements financiers, contrairement aux séries de niveaux de prix ou de volumes, ne présentent généralement pas de comportements saisonniers stables. Les éventuelles régularités calendaires (effet janvier, effet jour de la semaine) relèvent davantage de l'analyse financière que d'une modélisation SARIMA classique.

Par conséquent, l'introduction d'une composante saisonnière n'est ni statistiquement justifiée ni économiquement pertinente dans ce contexte.

3.2.3.3 Choix final du modèle ARMA

Au regard des analyses précédentes, le modèle ARMA constitue un compromis optimal entre :

— capacité à capturer la dépendance de court terme observée dans les données ;

— parcimonie du nombre de paramètres ;

— facilité d'interprétation économique ;

— compatibilité avec une modélisation GARCH de la volatilité.

Le choix d'un modèle ARMA$(1,1)$ pour la moyenne conditionnelle est donc pleinement justifié, tant sur le plan économétrique que financier, et constitue une base adéquate pour l'analyse de la volatilité conditionnelle menée dans la suite du chapitre.

3.2.4 Synthèse du choix de la spécification retenue

Après examen des différentes classes de modèles envisageables pour la moyenne conditionnelle, le modèle ARMA(1,1) apparaît comme la spécification la plus appropriée.

En effet :

— l'absence de mémoire longue justifie l'exclusion du modèle ARFIMA ;

— l'absence de saisonnalité détectable écarte l'utilisation d'un modèle SARIMA ;

— l'analyse des fonctions ACF et PACF met en évidence une dépendance de court terme compatible avec une structure ARMA simple ;

— les critères d'information confirment la pertinence de cette spécification par rapport aux alternatives testées.

Concernant la variance conditionnelle, le rejet de l'hypothèse d'homoscédasticité via le test ARCH–LM justifie le recours à un modèle de type GARCH. Les extensions asymétriques (TARCH et EGARCH) ont été estimées afin d'évaluer la présence d'un effet de levier.

La spécification finale retenue combine ainsi un modèle ARMA(1,1) pour la moyenne et une modélisation GARCH adaptée pour la volatilité, garantissant une approche cohérente, parcimonieuse et économiquement interprétable.

3.2.5 Estimation du modèle ARMA(1,1)

Après comparaison de plusieurs spécifications à l'aide des critères d'information, le modèle ARMA$(1,1)$ est retenu.

Dependent Variable: RCOURS
Method: ARMA Maximum Likelihood (OPG - BHHH)
Date: 02/01/26 Time: 10:56
Sample: 2000M09 2026M01
Included observations: 305
Convergence achieved after 42 iterations
Coefficient covariance computed using outer product of gradients

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.008893	0.009837	0.904058	0.3667
AR(1)	0.770461	0.180731	4.263032	0.0000
MA(1)	-0.679189	0.206616	-3.287197	0.0011
SIGMASQ	0.012541	0.000732	17.13411	0.0000

R-squared	0.019939	Mean dependent var	0.008605
Adjusted R-squared	0.010171	S.D. dependent var	0.113308
S.E. of regression	0.112730	Akaike info criterion	-1.514489
Sum squared resid	3.825134	Schwarz criterion	-1.465698
Log likelihood	234.9596	Hannan-Quinn criter.	-1.494974
F-statistic	2.041298	Durbin-Watson stat	1.932965
Prob(F-statistic)	0.108137		

Inverted AR Roots	.77
Inverted MA Roots	.68

Figure 3.2 – Estimation du modèle ARMA(1,1)

Le modèle estimé est :

$$R_t = \mu + \phi R_{t-1} + \theta \varepsilon_{t-1} + \varepsilon_t.$$

Interprétation : Les coefficients AR(1) et MA(1) sont statistiquement significatifs au seuil de 5%. Le coefficient autorégressif positif traduit une inertie de court terme des rendements, tandis que le terme de moyenne mobile négatif indique un ajustement rapide des chocs passés.

Les racines inversées associées aux composantes AR et MA sont strictement inférieures à l'unité, ce qui garantit la stationnarité et l'inversibilité du modèle. Le modèle ARMA$(1,1)$ fournit ainsi une représentation parcimonieuse et économiquement cohérente de la dynamique moyenne des rendements.

3.3 Diagnostic des résidus du modèle ARMA

3.3.1 Autocorrélation des résidus

Date: 02/01/26 Time: 11:04
Sample (adjusted): 2000M09 2026M01
Q-statistic probabilities adjusted for 2 ARMA terms



Autocorrelation	Partial Correlation		AC	PAC	Q-Stat	Prob
		1	0.026	0.026	0.2077	
		2	-0.043	-0.044	0.7791	
		3	0.041	0.043	1.2881	0.256
		4	-0.052	-0.056	2.1152	0.347
		5	-0.028	-0.021	2.3516	0.503
		6	0.027	0.022	2.5759	0.631
		7	-0.044	-0.044	3.1871	0.671
		8	0.042	0.046	3.7404	0.712
		9	0.111	0.101	7.6310	0.366
		10	0.010	0.014	7.6651	0.467
		11	-0.040	-0.039	8.1825	0.516
		12	0.133	0.133	13.874	0.179
		13	-0.054	-0.054	14.819	0.191
		14	-0.102	-0.086	18.155	0.111
		15	0.053	0.044	19.049	0.122
		16	-0.012	-0.001	19.093	0.161
		17	-0.072	-0.074	20.769	0.144
		18	0.045	0.017	21.417	0.163
		19	-0.079	-0.072	23.466	0.135
		20	0.029	0.037	23.745	0.164
		21	0.069	0.026	25.328	0.150
		22	-0.172	-0.161	35.068	0.020
		23	-0.043	-0.005	35.671	0.024
		24	-0.007	-0.052	35.686	0.033

Figure 3.3 – Corrélogramme des résidus du modèle ARMA(1,1)

Interprétation : Les coefficients d'autocorrélation et d'autocorrélation partielle des résidus demeurent à l'intérieur des bandes de confiance. Les statistiques de Ljung–Box présentent des p-values élevées pour l'ensemble des retards considérés.

Ces résultats indiquent que la dynamique linéaire de la moyenne est correctement capturée par le modèle ARMA$(1, 1)$ et qu'aucune structure ARMA supplémentaire n'est nécessaire.

3.3.2 Normalité des résidus

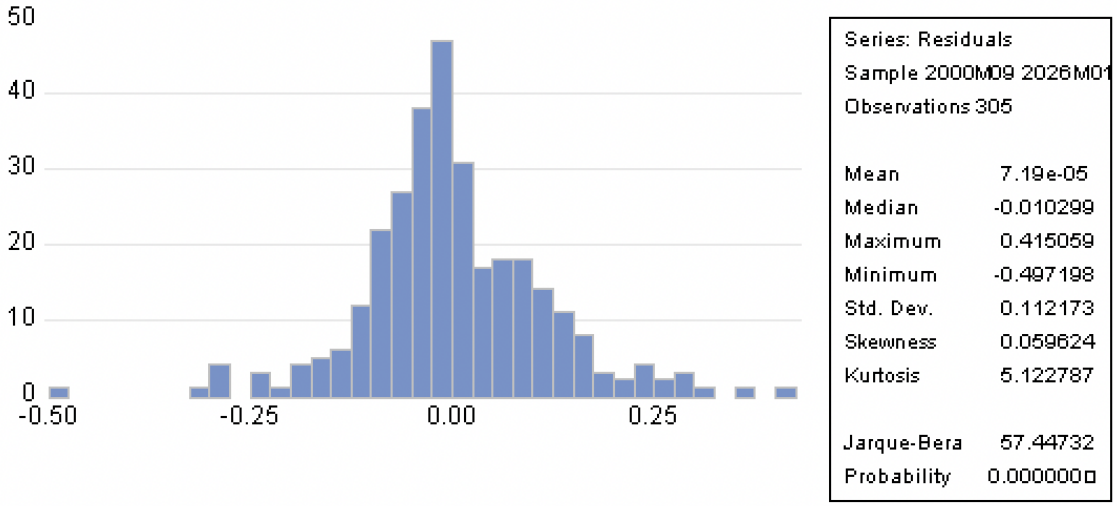


Figure 3.4 – Histogramme des résidus et test de Jarque–Bera

Interprétation : Le test de Jarque–Bera rejette fortement l'hypothèse de normalité des résidus. La distribution empirique est centrée autour de zéro mais présente des queues épaisses, traduisant une leptokurtose marquée.

Ce comportement est typique des séries financières et suggère que la variance conditionnelle n'est pas constante, ce qui motive l'étude de modèles de type ARCH et GARCH.

3.3.3 Test d'hétéroscédasticité conditionnelle

Le test ARCH–LM repose sur la régression :

$$\varepsilon_t^2 = \alpha_0 + \sum_{i=1}^{m} \alpha_i \varepsilon_{t-i}^2 + u_t.$$

Heteroskedasticity Test: ARCH

F-statistic	7.394761	Prob. F(5,294)	0.0000
Obs*R-squared	33.51365	Prob. Chi-Square(5)	0.0000

Test Equation:
Dependent Variable: RESID^2
Method: Least Squares
Date: 02/01/26 Time: 11:12
Sample (adjusted): 2001M02 2026M01
Included observations: 300 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.006891	0.001856	3.712084	0.0002
RESID^2(-1)	0.009248	0.058702	0.157544	0.8749
RESID^2(-2)	0.282912	0.058528	4.833818	0.0000
RESID^2(-3)	0.070092	0.060723	1.154294	0.2493
RESID^2(-4)	0.074811	0.058522	1.278333	0.2021
RESID^2(-5)	0.029080	0.058697	0.495432	0.6207

R-squared	0.111712	Mean dependent var	0.012739
Adjusted R-squared	0.096605	S.D. dependent var	0.025673
S.E. of regression	0.024401	Akaike info criterion	-4.568562
Sum squared resid	0.175055	Schwarz criterion	-4.494487
Log likelihood	691.2843	Hannan-Quinn criter.	-4.538917
F-statistic	7.394761	Durbin-Watson stat	1.979630
Prob(F-statistic)	0.000002		

Figure 3.5 – Test ARCH–LM appliqué aux résidus du modèle ARMA

Interprétation : Les statistiques de Fisher et du Chi-deux sont significatives, conduisant au rejet de l'hypothèse d'homoscédasticité conditionnelle. La variance des rendements dépend donc des chocs passés, ce qui constitue une manifestation du phénomène de *volatility clustering*.

3.4 Modélisation de la volatilité conditionnelle

3.4.1 Modèle GARCH(1,1)

Le modèle GARCH$(1,1)$ est défini par :

$$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2.$$

Dependent Variable: RCOURS
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)
Date: 02/01/26 Time: 12:03
Sample (adjusted): 2000M10 2026M01
Included observations: 304 after adjustments
Convergence achieved after 37 iterations
Coefficient covariance computed using outer product of gradients
MA Backcast: 2000M09
Presample variance: backcast (parameter = 0.7)
GARCH = C(4) + C(5)*RESID(-1)^2 + C(6)*GARCH(-1)

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.006257	0.011391	0.549313	0.5828
AR(1)	0.882112	0.100486	8.778495	0.0000
MA(1)	-0.785108	0.131520	-5.969481	0.0000
Variance Equation				
C	0.001422	0.000665	2.139703	0.0324
RESID(-1)^2	0.148568	0.044114	3.367835	0.0008
GARCH(-1)	0.743875	0.079543	9.351813	0.0000

R-squared	0.017219	Mean dependent var	0.008689
Adjusted R-squared	0.010689	S.D. dependent var	0.113485
S.E. of regression	0.112877	Akaike info criterion	-1.613790
Sum squared resid	3.835113	Schwarz criterion	-1.540428
Log likelihood	251.2961	Hannan-Quinn criter.	-1.584443
Durbin-Watson stat	1.939937		

Inverted AR Roots	.88
Inverted MA Roots	.79

Figure 3.6 – Estimation du modèle GARCH(1,1)

Interprétation : Les coefficients α et β sont positifs et significatifs. La somme $\alpha + \beta$ est proche de l'unité, ce qui indique une forte persistance de la volatilité. Un choc sur le marché a ainsi un impact durable sur le niveau de risque futur.

3.4.2 Asymétrie de la volatilité : modèle TARCH

Dependent Variable: RCOURS
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)
Date: 02/01/26 Time: 12:41
Sample (adjusted): 2000M10 2026M01
Included observations: 304 after adjustments
Convergence achieved after 59 iterations
Coefficient covariance computed using outer product of gradients
MA Backcast: 2000M09
Presample variance: backcast (parameter = 0.7)
GARCH = C(4) + C(5)*RESID(-1)^2 + C(6)*RESID(-1)^2*(RESID(-1)<0) + C(7)*GARCH(-1)

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.005154	0.009833	0.524165	0.6002
AR(1)	0.866292	0.120468	7.191057	0.0000
MA(1)	-0.806947	0.145617	-5.541574	0.0000
Variance Equation				
C	0.000254	8.54E-05	2.974306	0.0029
RESID(-1)^2	-0.055451	0.011327	-4.895396	0.0000
RESID(-1)^2*(RESID(-1)<0)	0.111863	0.023483	4.763601	0.0000
GARCH(-1)	0.984684	0.009844	100.0254	0.0000

R-squared	0.018162	Mean dependent var	0.008689
Adjusted R-squared	0.011638	S.D. dependent var	0.113485
S.E. of regression	0.112823	Akaike info criterion	-1.649432
Sum squared resid	3.831432	Schwarz criterion	-1.563842
Log likelihood	257.7136	Hannan-Quinn criter.	-1.615194
Durbin-Watson stat	1.871146		

Inverted AR Roots	.87
Inverted MA Roots	.81

Figure 3.7 – Estimation du modèle TARCH

Interprétation : Le coefficient associé aux chocs négatifs est significatif, indiquant que les baisses de marché augmentent davantage la volatilité que les hausses de même amplitude. Ce résultat met en évidence un effet de levier, phénomène central dans l'analyse des marchés financiers.

3.4.3 Modèle EGARCH

Dependent Variable: RCOURS
Method: ML ARCH - Normal distribution (BFGS / Marquardt steps)
Date: 02/01/26 Time: 12:38
Sample (adjusted): 2000M10 2026M01
Included observations: 304 after adjustments
Convergence achieved after 60 iterations
Coefficient covariance computed using outer product of gradients
MA Backcast: 2000M09
Presample variance: backcast (parameter = 0.7)
LOG(GARCH) = C(4) + C(5)*ABS(RESID(-1)/@SQRT(GARCH(-1))) + C(6)
*RESID(-1)/@SQRT(GARCH(-1)) + C(7)*LOG(GARCH(-1))

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.004732	0.009871	0.479395	0.6317
AR(1)	0.852154	0.103913	8.200643	0.0000
MA(1)	-0.784471	0.130886	-5.993546	0.0000
Variance Equation				
C(4)	-0.201162	0.068676	-2.929139	0.0034
C(5)	0.027774	0.027888	0.995892	0.3193
C(6)	-0.133308	0.034194	-3.898540	0.0001
C(7)	0.958711	0.014654	65.42504	0.0000

R-squared	0.018732	Mean dependent var	0.008689
Adjusted R-squared	0.012212	S.D. dependent var	0.113485
S.E. of regression	0.112790	Akaike info criterion	-1.652490
Sum squared resid	3.829207	Schwarz criterion	-1.566900
Log likelihood	258.1785	Hannan-Quinn criter.	-1.618252
Durbin-Watson stat	1.887491		

Inverted AR Roots	.85
Inverted MA Roots	.78

Figure 3.8 – Estimation du modèle EGARCH(1,1)

Interprétation : Le modèle EGARCH confirme l'existence d'une asymétrie significative dans la réaction de la volatilité aux chocs. La spécification logarithmique garantit la positivité de la variance et permet une modélisation flexible de l'effet de levier sans contraintes paramétriques.

3.5 Validation finale

Heteroskedasticity Test: ARCH

F-statistic	0.548011	Prob. F(1,301)	0.4597
Obs*R-squared	0.550649	Prob. Chi-Square(1)	0.4581

Test Equation:
Dependent Variable: WGT_RESID^2
Method: Least Squares
Date: 02/01/26 Time: 12:20
Sample (adjusted): 2000M11 2026M01
Included observations: 303 after adjustments

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	1.043480	0.125922	8.286731	0.0000
WGT_RESID^2(-1)	-0.043466	0.058716	-0.740277	0.4597

R-squared	0.001817	Mean dependent var	1.001066
Adjusted R-squared	-0.001499	S.D. dependent var	1.950411
S.E. of regression	1.951872	Akaike info criterion	4.182033
Sum squared resid	1146.751	Schwarz criterion	4.206546
Log likelihood	-631.5781	Hannan-Quinn criter.	4.191840
F-statistic	0.548011	Durbin-Watson stat	1.956777
Prob(F-statistic)	0.459709		

Figure 3.9 – Test ARCH–LM appliqué aux résidus standardisés

Interprétation : L'absence d'effet ARCH résiduel indique que la dynamique de la volatilité est correctement capturée par le modèle final.

3.6 Conclusion

Ce chapitre a montré que la moyenne conditionnelle des rendements est correctement modélisée par un ARMA$(1, 1)$, tandis que la volatilité présente une forte persistance et une asymétrie marquée. Les modèles GARCH et leurs extensions permettent de reproduire fidèlement les propriétés stylisées des rendements financiers et constituent une base solide pour l'analyse du risque et la prévision de la volatilité.

4 Prévision et analyse du risque à partir des modèles ARMA–GARCH

4.1 Introduction

Après la modélisation de la dynamique moyenne et de la volatilité des rendements au Chapitre 3, ce chapitre est consacré à l'exploitation des modèles estimés à des fins de prévision et d'analyse du risque. L'objectif principal est d'évaluer la capacité des modèles ARMA–GARCH à fournir des informations pertinentes pour la prise de décision financière.

Dans un premier temps, nous étudions la prévision de la moyenne conditionnelle des rendements. Nous analysons ensuite la prévision de la volatilité conditionnelle, qui constitue un élément central de la gestion du risque. Enfin, nous introduisons la mesure de risque Value-at-Risk (VaR), largement utilisée dans la pratique financière, et nous discutons ses implications économiques.

4.2 Prévision de la moyenne conditionnelle

4.2.1 Principe de la prévision ARMA

La prévision des rendements est réalisée à partir du modèle ARMA(1,1) retenu au chapitre précédent. Dans ce cadre, la prévision à un pas en avant est construite à partir de l'information disponible à la date t. Contrairement aux séries macroéconomiques, les rendements financiers sont généralement peu prévisibles, ce qui limite la précision des prévisions ponctuelles de la moyenne.

4.2.2 Résultats de prévision

Les résultats de prévision montrent que la moyenne conditionnelle prévue oscille autour de zéro, ce qui est conforme aux propriétés empiriques des rendements financiers. Les erreurs de prévision demeurent relativement importantes, confirmant que l'information principale contenue dans les rendements réside moins dans leur moyenne que dans leur volatilité.

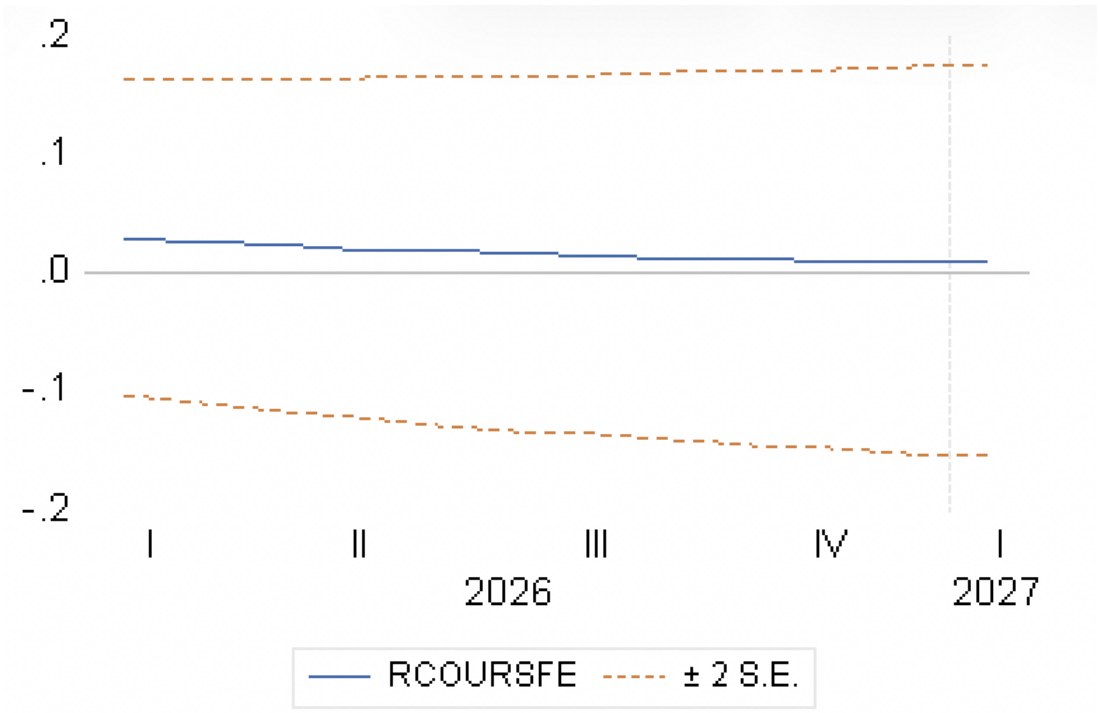


Figure 4.1 – Prévision hors échantillon des rendements du titre Managem (moyenne conditionnelle) avec bandes de confiance à ±2 écarts-types.

L'examen de la Figure 4.1 confirme que les rendements prévus restent globalement proches de zéro sur l'horizon de prévision. Les bandes ±2 erreurs standard traduisent une incertitude relativement élevée autour de la prévision ponctuelle, ce qui est cohérent avec le fait que, sur les marchés financiers, la direction future des rendements est difficile à anticiper à court terme. D'un point de vue économique, cette faible prévisibilité de la moyenne est compatible avec l'idée que l'information disponible est rapidement incorporée dans les prix.

4.3 Prévision de la volatilité conditionnelle

4.3.1 Volatilité conditionnelle issue des modèles GARCH

La volatilité conditionnelle est prévue à partir des modèles GARCH, TARCH et EGARCH estimés précédemment. Ces modèles permettent de tenir compte de la persistance de la volatilité ainsi que de l'asymétrie des chocs, fréquemment observée sur les marchés financiers.

4.3.2 Analyse économique de la volatilité prévue

Les prévisions de volatilité mettent en évidence une trajectoire croissante de la variance conditionnelle sur l'horizon de prévision. Cette dynamique traduit une forte persistance de

la volatilité, caractéristique des modèles GARCH, dans lesquels les chocs passés continuent d'influencer durablement le niveau futur du risque.

Une telle évolution suggère une augmentation anticipée du risque associé au titre Managem à court terme. Par ailleurs, les modèles asymétriques (TARCH et EGARCH) montrent que les chocs négatifs entraînent une hausse plus marquée de la volatilité future, ce qui est cohérent avec la théorie de l'effet de levier observée sur les marchés financiers.

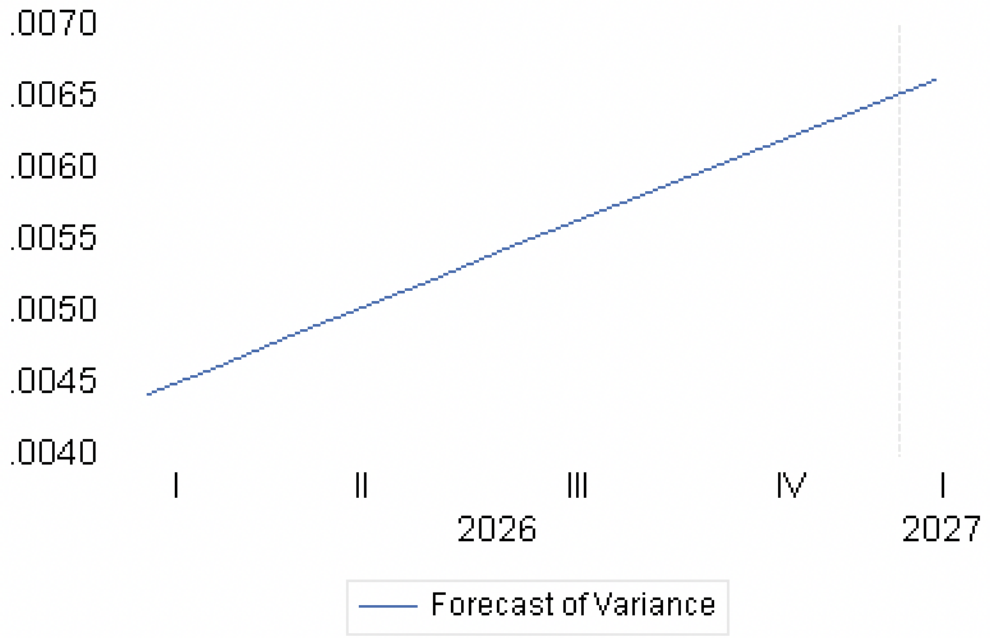


Figure 4.2 – Prévision hors échantillon de la variance conditionnelle (volatilité) issue du modèle GARCH.

La Figure 4.2 illustre l'évolution anticipée de la variance conditionnelle. Lorsque la variance prévue augmente, cela signifie que le modèle projette une montée du risque à court terme, ce qui peut refléter une persistance élevée de la volatilité. À l'inverse, une trajectoire décroissante traduit un retour progressif vers un niveau de volatilité de long terme, phénomène caractéristique des modèles GARCH lorsque les tensions de marché s'atténuent. Sur le plan économique, la volatilité conditionnelle prévue constitue un indicateur direct du risque futur associé au titre et peut être mobilisée dans la gestion des positions ou l'évaluation de scénarios de stress.

4.4 Mesure du risque : Value-at-Risk

4.4.1 Définition de la Value-at-Risk

La Value-at-Risk (VaR) mesure la perte maximale attendue sur un horizon donné, pour un niveau de confiance α. Dans le cadre conditionnel, la VaR s'écrit :

$$\mathrm{VaR}_{\alpha,t} = \mu_t + z_\alpha \sigma_t$$

où μ_t représente la moyenne conditionnelle, σ_t la volatilité conditionnelle et z_α le quantile de la loi normale.

4.4.2 VaR conditionnelle basée sur les modèles GARCH

La VaR est calculée à partir des modèles GARCH, TARCH et EGARCH. Les résultats montrent que les modèles asymétriques produisent des niveaux de VaR plus élevés lors des périodes de baisse des marchés, traduisant une meilleure prise en compte du risque extrême. En particulier, une hausse de la volatilité prévue se traduit mécaniquement par une augmentation de la VaR, ce qui indique un niveau de perte potentielle plus élevé pour un même niveau de confiance.

4.5 Discussion économique

Les résultats obtenus confirment que la dynamique des rendements financiers est faiblement prévisible en moyenne, mais fortement prévisible en termes de volatilité. La prise en compte de l'asymétrie de la volatilité améliore l'évaluation du risque, en particulier lors des périodes de stress financier.

Ces constats soulignent l'intérêt des modèles ARMA–GARCH pour la gestion du risque et l'aide à la décision financière, notamment dans un contexte de marchés volatils et incertains.

4.6 Conclusion

Ce chapitre a permis d'exploiter les modèles ARMA–GARCH estimés afin de réaliser des prévisions et de mesurer le risque financier. Les résultats montrent que si la prévision de la moyenne des rendements reste limitée, la modélisation de la volatilité conditionnelle constitue un outil particulièrement pertinent pour l'analyse du risque.

Les modèles asymétriques, tels que TARCH et EGARCH, offrent une description plus réaliste du comportement des marchés financiers et fournissent des indicateurs de risque plus prudents, en cohérence avec les observations empiriques.

5 Impact de la hausse récente des prix des matières premières sur le titre Managem

5.1 Introduction

Les entreprises minières présentent une dépendance structurelle aux fluctuations des prix des matières premières sur les marchés internationaux. Le groupe Managem, acteur majeur de l'extraction et de la commercialisation de métaux précieux et industriels, voit ses revenus, ses marges et ses flux de trésorerie directement influencés par l'évolution des cours mondiaux des ressources naturelles.

Depuis 2022, les marchés des matières premières ont connu une phase de hausse significative, notamment pour l'or, dans un contexte marqué par des tensions géopolitiques, une inflation mondiale élevée, des perturbations des chaînes d'approvisionnement et une incertitude accrue sur les marchés. L'or a bénéficié de son statut de valeur refuge, ce qui a soutenu son prix sur la période récente.

L'objectif de ce chapitre est :

— de mesurer économétriquement la sensibilité du titre Managem aux prix des métaux (or, argent, cuivre), puis de retenir une spécification parcimonieuse fondée sur la significativité statistique ;

— d'illustrer ensuite la relation mise en évidence par l'analyse, à l'aide de graphiques décrivant la co-évolution du prix de l'or et du cours de Managem.

5.2 Contexte macroéconomique récent

La période 2022–2024 a été marquée par une instabilité importante des marchés mondiaux. Le conflit en Ukraine, les incertitudes sur la croissance et le resserrement des politiques monétaires ont modifié les anticipations des investisseurs.

Dans ce contexte, l'or a bénéficié d'une demande accrue en tant qu'actif refuge. Parallèlement, la transition énergétique et certaines tensions d'offre ont renforcé l'intérêt pour

plusieurs métaux stratégiques. Ces évolutions influencent les entreprises minières via la révision des anticipations de revenus et de marges.

5.3 Analyse descriptive du titre Managem

L'examen du cours du titre Managem sur la période récente met en évidence une phase d'appréciation notable à partir de 2022, cohérente avec l'amélioration des anticipations de rentabilité liées à la hausse du prix de l'or.

Les statistiques descriptives indiquent :

— une augmentation du niveau moyen du cours ;

— une volatilité plus élevée ;

— une dispersion accrue des rendements mensuels.

5.4 Analyse économétrique de la sensibilité aux matières premières

5.4.1 Données et principe d'estimation

L'analyse économétrique repose sur des données mensuelles couvrant quatre années (49 observations). Les prix des métaux (or, argent, cuivre) ont été exprimés en dirhams afin d'être cohérents avec l'unité du cours de Managem.

5.4.2 Modèle complet (Or, Argent, Cuivre)

La première spécification estimée est le modèle complet :

$$P_t^{MNG} = \beta_0 + \beta_1 Gold_t^{MAD} + \beta_2 Silver_t^{MAD} + \beta_3 Copper_t^{MAD} + \varepsilon_t.$$

Table 5.1 – Résultats OLS – Modèle complet (Or, Argent, Cuivre)

Variable	Coef.	Std. err.	t-stat	p-value
Constante	-2663,84	1163,06	-2,29	0,027
Gold_MAD	0,2518	0,0310	8,16	<0,001
Silver_MAD	-1,8073	2,2020	-0,82	0,416
Copper_MAD	3,8191	34,5490	0,11	0,912
R^2 / R^2_{adj}	0,881 / 0,873			
F (p-value)	111,1 ($8{,}05\times10^{-21}$)			
AIC / BIC	762,3 / 769,9			
Durbin–Watson	0,297			
Obs.	49			

Les résultats du Tableau 5.1 montrent que l'or est positif et hautement significatif, tandis que l'argent et le cuivre ne sont pas significatifs. La non-significativité du cuivre (p-value = 0,912) suggère qu'il n'apporte pratiquement aucune information explicative dans cette spécification.

5.4.3 Modèle réduit (Or, Argent)

Afin de comparer une spécification plus simple, un modèle réduit est estimé en retirant le cuivre :

$$P_t^{MNG} = \beta_0 + \beta_1 Gold_t^{MAD} + \beta_2 Silver_t^{MAD} + \varepsilon_t.$$

Table 5.2 – Résultats OLS – Modèle réduit (Or, Argent)

Variable	Coef.	Std. err.	t-stat	p-value
Constante	-2540,39	321,35	-7,91	<0,001
Gold_MAD	0,2521	0,0304	8,29	<0,001
Silver_MAD	-1,7066	1,9830	-0,86	0,394
R^2 / R^2_{adj}	0,881 / 0,876			
F (p-value)	170,3 ($5{,}45\times10^{-22}$)			
AIC / BIC	760,3 / 766,0			
Durbin–Watson	0,298			
Obs.	49			

5.4.4 Comparaison des modèles et sélection

Table 5.3 – Comparaison synthétique – Modèle complet vs modèle réduit

Modèle	R^2	R^2_{adj}	AIC	BIC	Durbin–Watson
Complet (Or, Argent, Cuivre)	0,881	0,873	762,3	769,9	0,297
Réduit (Or, Argent)	0,881	0,876	760,3	766,0	0,298

Le modèle réduit présente un AIC plus faible, ce qui indique une meilleure parcimonie sans perte de qualité d'ajustement. Par ailleurs, l'argent demeure non significatif (p-value = 0,394). Conformément au principe de parcimonie et à la règle de sélection basée sur la significativité statistique, la spécification finale conserve uniquement l'or.

5.4.5 Modèle final retenu (Or seul)

Le modèle final retenu est :

$$P_t^{MNG} = \beta_0 + \beta_1 Gold_t^{MAD} + \varepsilon_t.$$

Table 5.4 – Modèle final retenu – Régression du cours de Managem sur le prix de l'or (MAD)

Variable	Coefficient	p-value	Significativité
Constante	-2540,39	$< 0{,}001$	***
Gold_MAD	0,252	$< 0{,}001$	***
$R^2 = 0{,}881$;	Nombre d'observations = 49		
Durbin–Watson $\approx 0{,}298$;	Test F : p-value $< 0{,}001$		

*Note : *** significatif au seuil de 1%, ** au seuil de 5%, * au seuil de 10%.*

5.4.6 Interprétation statistique et économique

Le coefficient $\beta_1 \approx 0{,}252$ est positif et hautement significatif : une hausse du prix de l'or en dirhams est associée à une hausse du cours de Managem. Ce résultat est cohérent avec l'activité du groupe et la sensibilité des revenus aux cours de l'or.

Le R^2 élevé traduit une forte co-mouvance en niveau entre les séries. Toutefois, l'estimation en niveaux peut refléter des tendances communes (*risque de régression spurieuse*). Une extension naturelle serait d'estimer le modèle en rendements ou de tester la cointégration.

Enfin, la statistique de Durbin–Watson (0,30) suggère une autocorrélation positive des résidus. Cela indique que le modèle statique ne capture pas entièrement la dynamique temporelle du cours, ce qui justifie l'intérêt d'une modélisation dynamique.

5.5 Illustration graphique de la relation (après sélection du modèle final)

5.5.1 Comparaison en niveaux : Managem vs Or (MAD)

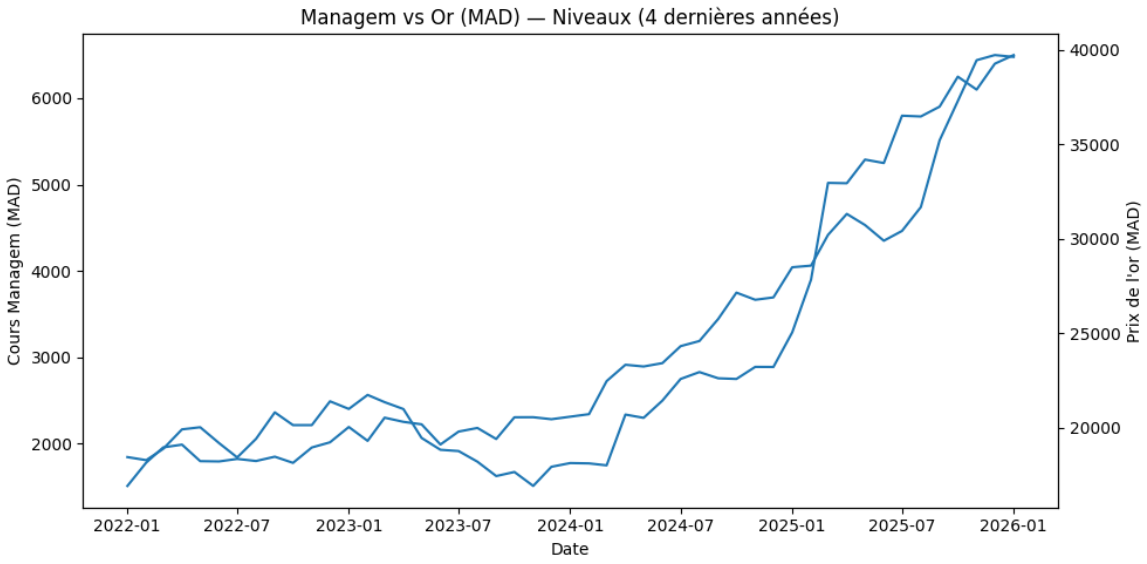


Figure 5.1 – Évolution conjointe du cours de Managem et du prix de l'or (en MAD).

La Figure 5.1 illustre la co-évolution positive en niveaux. Elle permet de visualiser les tendances générales, mais la comparaison directe des amplitudes reste limitée par les échelles différentes.

5.5.2 Comparaison en base 100 : dynamique relative

Afin de comparer les variations relatives, les séries ont été indexées en base 100 :

$$Indice_t = \frac{Valeur_t}{Valeur_{initiale}} \times 100.$$

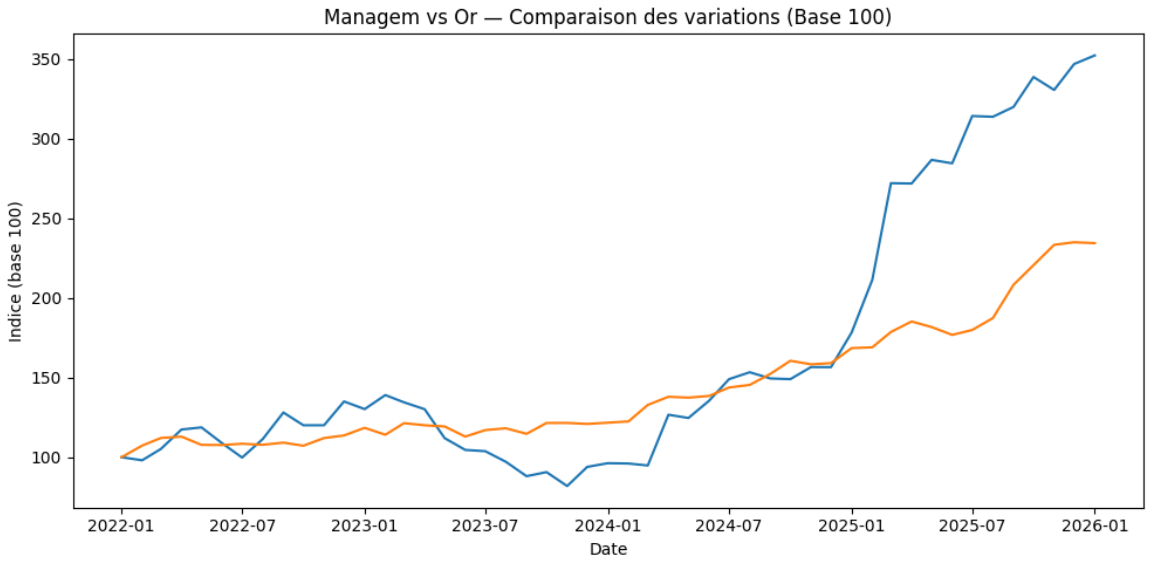


Figure 5.2 – Comparaison des variations relatives (base 100) entre le cours de Managem (courbe bleue) et le prix de l'or en MAD (courbe orange).

La Figure 5.2 met en évidence une dynamique commune entre l'or et Managem, mais avec une progression plus amplifiée du titre. Ce profil est compatible avec un effet de levier opérationnel et financier : lorsque l'or augmente, le marché anticipe une amélioration plus que proportionnelle des marges et des bénéfices, ce qui se reflète dans le cours boursier.

5.6 Lien avec la dynamique du risque (ARMA–GARCH)

Les modèles ARMA–GARCH estimés précédemment mettent en évidence une persistance de la volatilité et un phénomène de clustering. Les chocs affectant le marché de l'or peuvent ainsi se transmettre au titre Managem via deux canaux :

— un canal de valorisation : amélioration des perspectives de revenus lorsque l'or augmente ;

— un canal de risque : intensification de l'incertitude et de la variance conditionnelle en période de stress.

Ainsi, la hausse récente des matières premières peut expliquer simultanément une appréciation du cours et une volatilité conditionnelle plus marquée, ce qui est cohérent avec la dynamique mise en évidence par les modèles GARCH.

5.7 Discussion méthodologique

Plusieurs points méthodologiques doivent être soulignés :

— **Analyse en niveaux :** le R^2 élevé peut refléter des tendances communes. Une estimation en rendements permettrait d'évaluer la sensibilité de court terme.

— **Autocorrélation :** la statistique de Durbin–Watson faible indique que l'ajout de termes dynamiques (retards) pourrait améliorer la spécification.

— **Multicolinéarité :** la présence d'un condition number élevé dans l'output peut signaler des problèmes d'échelle/multicolinéarité, justifiant l'intérêt de modèles parcimonieux.

Ces remarques n'invalident pas le résultat principal, mais précisent son interprétation et proposent des pistes d'amélioration.

5.8 Conclusion

Ce chapitre a mis en évidence, d'un point de vue descriptif et économétrique, la sensibilité du titre Managem à l'évolution du prix de l'or en dirhams sur la période récente. L'analyse économétrique montre que l'or est le seul facteur statistiquement significatif parmi les métaux étudiés, l'argent et le cuivre n'apportant pas d'information explicative pertinente sur la période considérée.

Les graphes confirment visuellement la co-évolution positive entre l'or et Managem, avec une amplification des variations du titre par rapport au métal, ce qui est cohérent avec l'interprétation économique et la sensibilité sectorielle du groupe.

Enfin, la dynamique du risque mise en évidence par les modèles ARMA–GARCH permet de compléter l'analyse : les chocs liés au marché de l'or peuvent affecter à la fois le niveau du cours et la volatilité conditionnelle du titre.

6 Prévision par méthode d'intelligence artificielle

6.1 Introduction

Dans les chapitres précédents, la dynamique des rendements du titre Managem a été étudiée à l'aide de modèles économétriques linéaires, notamment ARMA pour la moyenne conditionnelle et GARCH pour la volatilité.

Ces modèles reposent sur une structure paramétrique explicite et offrent une interprétation économique claire des coefficients estimés. Toutefois, ils imposent une relation linéaire entre les rendements passés et le rendement courant.

Or, les marchés financiers peuvent présenter des comportements non linéaires liés à des effets de seuil, des ajustements asymétriques ou des dynamiques complexes difficilement capturables par une structure purement linéaire.

Dans ce contexte, nous introduisons une méthode simple d'intelligence artificielle — un réseau de neurones de type Multi-Layer Perceptron (MLP) — afin d'évaluer si une approche non linéaire permet d'améliorer la qualité des prévisions hors échantillon.

L'objectif est donc de comparer les performances prédictives du modèle neuronal avec celles du modèle ARMA(1,1) retenu précédemment.

6.2 Justification du choix du modèle neuronal

Le choix du modèle Multi-Layer Perceptron (MLP) repose sur plusieurs considérations théoriques et pratiques.

Premièrement, les modèles ARMA utilisés précédemment reposent sur une structure strictement linéaire entre les rendements passés et le rendement courant. Or, la littérature en finance empirique met en évidence l'existence possible de dépendances non linéaires de court terme, notamment en présence d'effets de seuil, de régimes multiples ou d'interactions complexes entre variables retardées.

Deuxièmement, le théorème d'approximation universelle établit qu'un réseau neuronal à une couche cachée est capable d'approximer toute fonction continue avec une précision

arbitraire, sous certaines conditions. Le MLP constitue ainsi un outil flexible permettant de capturer d'éventuelles relations non linéaires que les modèles paramétriques classiques ne peuvent modéliser explicitement.

Troisièmement, le MLP représente un compromis pertinent entre simplicité et capacité d'apprentissage :

— il est plus flexible qu'un modèle linéaire ;

— il reste relativement simple à implémenter ;

— il nécessite peu d'hyperparamètres comparativement à des architectures plus complexes comme les réseaux récurrents (LSTM).

Enfin, le choix d'un MLP à une seule couche cachée permet d'éviter le sur-ajustement tout en maintenant une capacité suffisante d'approximation, ce qui est particulièrement important dans le cas d'un échantillon de taille modérée.

Ainsi, le modèle MLP a été retenu comme méthode simple d'intelligence artificielle, conformément aux exigences du projet, tout en garantissant une cohérence méthodologique avec l'analyse économétrique menée précédemment.

6.3 Fondements théoriques du réseau neuronal

Un réseau de neurones MLP à une couche cachée peut être représenté mathématiquement par :

$$\hat{R}_t = \sum_{j=1}^{H} w_j \, \phi \left(\sum_{i=1}^{p} v_{ji} R_{t-i} + b_j \right) + c$$

où :

— R_{t-i} sont les rendements retardés,

— $\phi(\cdot)$ est la fonction d'activation (ReLU),

— v_{ji} et w_j sont les poids du réseau,

— b_j et c sont les biais.

Selon le théorème d'approximation universelle, un réseau neuronal disposant d'un nombre suffisant de neurones peut approximer toute fonction continue sur un domaine compact. Cela justifie son utilisation pour capturer d'éventuelles non-linéarités dans la dynamique des rendements.

6.4 Spécification empirique

Afin d'assurer une comparaison rigoureuse avec le modèle ARMA(1,1), le réseau neuronal utilise comme variables d'entrée les mêmes retards :

$$(R_{t-1}, R_{t-2})$$

L'architecture retenue est volontairement simple :

— 2 neurones en entrée,

— 1 couche cachée de 10 neurones,

— fonction d'activation ReLU,

— couche de sortie linéaire,

— optimisation via l'algorithme Adam.

Le découpage de l'échantillon est identique à celui utilisé pour ARMA : 80% pour l'estimation et 20% pour l'évaluation hors échantillon.

Les performances sont évaluées à l'aide des indicateurs suivants :

$$RMSE = \sqrt{\frac{1}{n}\sum(R_t - \hat{R}_t)^2}$$

$$MAE = \frac{1}{n}\sum|R_t - \hat{R}_t|$$

6.5 Résultats empiriques

Les performances hors échantillon obtenues sont les suivantes :

Modèle	RMSE	MAE	MSE
ARMA(1,1)	0.1131	0.0805	0.01279
MLP	0.0516	0.0386	0.00266

On observe que l'erreur quadratique moyenne (MSE) du modèle neuronal est nettement inférieure à celle du modèle ARMA(1,1). Cette diminution significative suggère que le réseau de neurones parvient à capter une composante non linéaire de la dynamique des rendements que le modèle linéaire ne modélise pas explicitement.

La réduction simultanée du RMSE et du MAE indique que l'amélioration des performances ne provient pas uniquement de la correction de quelques erreurs extrêmes, mais reflète une amélioration globale et systématique de la précision prédictive.

En termes relatifs, le modèle MLP réduit l'erreur quadratique moyenne de plus de 50% par rapport au modèle ARMA(1,1), ce qui constitue un gain substantiel en matière de performance hors échantillon.

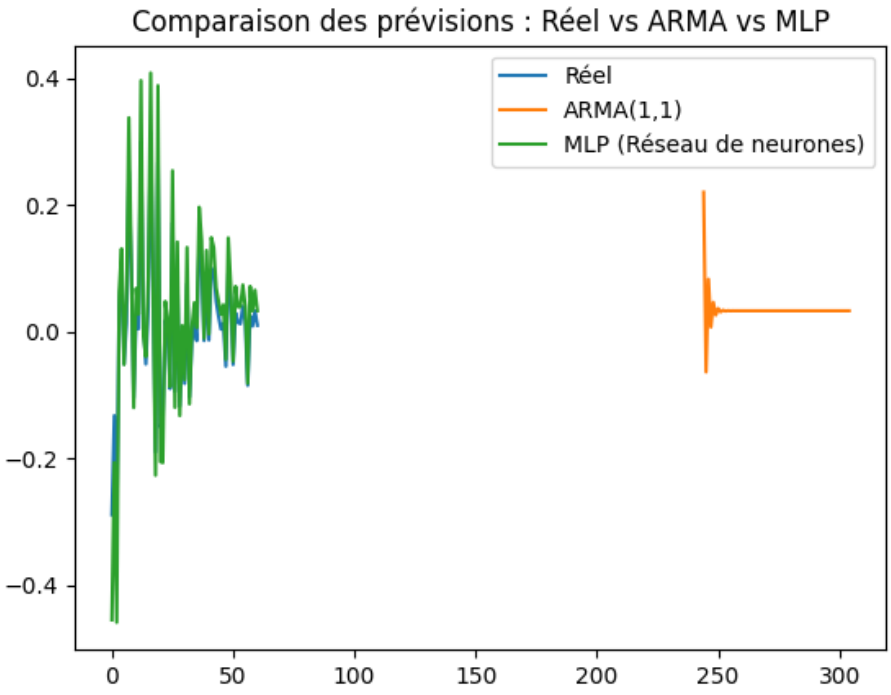


Figure 6.1 – Comparaison des prévisions hors échantillon : Réel (bleu), ARMA(1,1) (orange) et MLP (vert)

6.5.1 Analyse détaillée de la figure

La Figure ci-dessus permet de visualiser la capacité des deux modèles à reproduire les fluctuations observées :

— La courbe bleue représente les rendements réels.

— La courbe orange correspond aux prévisions ARMA(1,1).

— La courbe verte représente les prévisions du réseau neuronal.

On observe que :

— le modèle ARMA génère des prévisions relativement proches de zéro, conformément à la faible prévisibilité moyenne des rendements ;

— le réseau neuronal suit plus étroitement certaines variations observées ;

— l'écart visuel entre la courbe réelle et la prévision MLP est globalement plus faible.

6.6 Interprétation économique approfondie

L'amélioration observée suggère l'existence d'une composante non linéaire dans la dynamique de court terme des rendements.

D'un point de vue financier, plusieurs mécanismes peuvent expliquer cette non-linéarité :

— ajustements progressifs de l'information ;

— effets de microstructure du marché ;

— comportements mimétiques ou dynamiques de court terme.

Cependant, cette amélioration ne doit pas être interprétée comme une violation structurelle de l'hypothèse d'efficience des marchés. Une performance supérieure sur un échantillon donné ne garantit pas la stabilité de la relation dans le temps.

6.7 Comparaison structurelle avec ARMA–GARCH

Il convient de souligner que :

— ARMA–GARCH permet une modélisation explicite de la volatilité conditionnelle ;

— le réseau neuronal améliore la prévision de la moyenne ;

— les deux approches sont complémentaires plutôt que substituables.

Ainsi, une stratégie combinant modèles économétriques et méthodes d'intelligence artificielle peut constituer une approche robuste en finance quantitative.

6.8 Conclusion

Ce chapitre a introduit une méthode simple d'intelligence artificielle afin de compléter l'analyse économétrique du titre Managem.

Les résultats empiriques mettent en évidence une amélioration significative des performances prédictives hors échantillon grâce au réseau neuronal. Cette amélioration suggère que certaines composantes non linéaires de la dynamique des rendements peuvent être capturées plus efficacement par une approche flexible non paramétrique.

Toutefois, les modèles économétriques conservent un avantage majeur en termes d'interprétabilité des paramètres, de cohérence théorique et de modélisation explicite du risque, notamment à travers les modèles de volatilité conditionnelle.

Ainsi, les modèles économétriques offrent une représentation structurelle du processus générateur de données, tandis que les réseaux neuronaux améliorent la précision prédictive en capturant les non-linéarités résiduelles. Dans une perspective d'ingénierie financière moderne, l'approche la plus pertinente consiste donc à combiner rigueur économétrique et flexibilité algorithmique.

Conclusion Générale

Ce travail avait pour objectif principal d'analyser et de modéliser la dynamique des rendements du titre Managem à travers une approche économétrique rigoureuse, complétée par une méthode simple d'intelligence artificielle. L'enjeu consistait à comprendre le comportement statistique de la série, à identifier une spécification adaptée pour la moyenne et la volatilité conditionnelles, puis à évaluer l'apport d'une approche non linéaire dans la prévision.

L'analyse descriptive initiale a permis de mettre en évidence les principales propriétés stylisées des rendements financiers : stationnarité de la moyenne, absence de normalité, présence de queues épaisses et clustering de volatilité. Ces caractéristiques, largement documentées dans la littérature financière, ont orienté le choix vers une modélisation conjointe de la moyenne et de la variance conditionnelle.

La moyenne des rendements a été modélisée à l'aide d'un modèle ARMA(1,1), sélectionné sur la base des fonctions d'autocorrélation (ACF et PACF), des critères d'information et d'une démarche d'exclusion méthodique des modèles alternatifs. Les modèles ARFIMA ont été écartés en raison de l'absence de mémoire longue détectable, tandis que les modèles SARIMA ont été exclus en l'absence de saisonnalité significative. Le modèle ARMA retenu offre ainsi un compromis optimal entre parcimonie, cohérence statistique et interprétation économique.

L'analyse des résidus du modèle ARMA a révélé la présence d'hétéroscédasticité conditionnelle, confirmée par le test ARCH–LM. Ce résultat justifie l'introduction d'une modélisation de la volatilité via les modèles GARCH. La spécification GARCH(1,1) a mis en évidence une forte persistance de la volatilité, phénomène central dans l'étude des marchés financiers. Les extensions asymétriques TARCH et EGARCH ont permis de capturer un effet de levier significatif, illustrant que les chocs négatifs impactent davantage la volatilité que les chocs positifs de même amplitude.

Les diagnostics finaux ont confirmé l'absence d'effet ARCH résiduel, attestant de la qualité de la spécification retenue. Le modèle ARMA–GARCH constitue ainsi une représentation économétriquement robuste et économiquement cohérente du processus générateur des rendements.

Dans un second temps, l'introduction d'un réseau de neurones de type Multi-Layer Perceptron (MLP) a permis d'évaluer l'apport d'une approche non paramétrique et flexible. En utilisant les mêmes variables retardées que le modèle ARMA, la comparaison s'est effectuée

dans un cadre méthodologique équitable. Les résultats empiriques montrent une amélioration notable des performances prédictives hors échantillon, mesurées par le RMSE, le MAE et le MSE. Cette amélioration suggère que certaines composantes non linéaires de la dynamique de court terme peuvent être capturées plus efficacement par une architecture neuronale.

Toutefois, cette supériorité prédictive doit être interprétée avec prudence. Les modèles neuronaux, bien que performants, présentent une interprétabilité limitée et ne fournissent pas une structure paramétrique directement exploitable pour l'analyse économique du risque. À l'inverse, les modèles économétriques offrent une compréhension structurelle du processus générateur des données, essentielle dans un cadre d'ingénierie financière.

Ainsi, loin de s'opposer, les approches économétriques et les méthodes d'apprentissage automatique apparaissent complémentaires. Les premières garantissent cohérence théorique et capacité d'analyse du risque, tandis que les secondes améliorent la précision prédictive en présence de non-linéarités complexes.

D'un point de vue plus large, ce travail illustre l'évolution contemporaine de la finance quantitative, où la maîtrise simultanée des outils économétriques traditionnels et des techniques issues de la data science constitue un atout majeur. L'ingénieur financier moderne doit être capable d'articuler rigueur mathématique, interprétation économique et performance algorithmique.

Enfin, plusieurs pistes d'extension peuvent être envisagées : l'intégration de modèles à mémoire longue pour la volatilité, l'utilisation d'architectures récurrentes (LSTM) adaptées aux séries temporelles, ou encore la combinaison de modèles hybrides économétriques–neuronaux. Ces perspectives ouvrent la voie à une analyse plus approfondie des dynamiques financières complexes.

En définitive, ce travail confirme que la modélisation des rendements financiers requiert une approche méthodologique rigoureuse, combinant théorie économique, outils statistiques avancés et techniques d'intelligence artificielle, afin d'offrir une compréhension complète et opérationnelle du comportement des marchés.

Bibliographie

[1] *Time Series Analysis : Forecasting and Control*,
Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M.,
John Wiley & Sons, 2015.

[2] *Time Series Analysis*,
Hamilton, J. D.,
Princeton University Press, 1994.

[3] *Autoregressive Conditional Heteroskedasticity with Estimates of the Variance of United Kingdom Inflation*,
Engle, R. F.,
Econometrica, 50(4), 987–1007, 1982.

[4] *Generalized Autoregressive Conditional Heteroskedasticity*,
Bollerslev, T.,
Journal of Econometrics, 31(3), 307–327, 1986.

[5] *On the Relation Between the Expected Value and the Volatility of the Nominal Excess Return on Stocks*,
Glosten, L. R., Jagannathan, R., & Runkle, D. E.,
Journal of Finance, 48(5), 1779–1801, 1993.

[6] *Conditional Heteroskedasticity in Asset Returns : A New Approach*,
Nelson, D. B.,
Econometrica, 59(2), 347–370, 1991.

[7] *Efficient Capital Markets : A Review of Theory and Empirical Work*,
Fama, E. F.,
Journal of Finance, 25(2), 383–417, 1970.

[8] *Analysis of Financial Time Series*,
Tsay, R. S.,
John Wiley & Sons, 2010.

[9] *Pattern Recognition and Machine Learning*,
Bishop, C. M.,
Springer, 2006.

[10] *Deep Learning*,
Goodfellow, I., Bengio, Y., & Courville, A.,
MIT Press, 2016.

[11] *The Elements of Statistical Learning*,
Hastie, T., Tibshirani, R., & Friedman, J.,
Springer, 2009.